A. 影子专家后台预热与权重复制

滑窗统计专家命中直方图
识别超阈值热点专家 (4× 负载)

在空闲卡冗余槽分配影子缓冲
异步 RDMA/NVLink 复制 36 MiB

复制期 (0.62~5.32 ms) 零阻塞
前台仍按旧路由表 v_t 分发

影子副本校验与算子预热就绪
标记 ShadowSlot 状态 READY

B. 路由表双缓冲原子切换与排空

构造新路由表 v_{t+1}:
热点专家按权重轮询多副本

微批边界原子交换路由表指针
新批次立即读取 v_{t+1} 分流

旧版本在途 Combine 引用计数
等待在途微批归并 (ref=0)

安全回收旧冷门副本冗余槽位
全程零停机、零丢包、等价