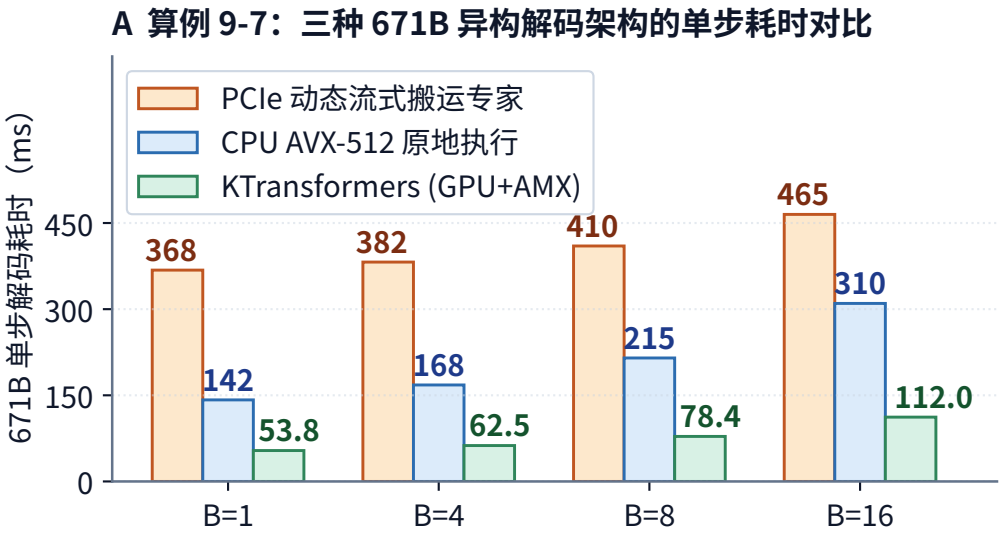
A 算例 9-7：三种 671B 异构解码架构的单步耗时对比
PCIe 动态流式搬运专家
CPU AVX-512 原地执行
KTransformers (GPU+AMX)
671B 单步解码耗时（ms）
0
150
300
450
368
142
53.8
382
168
62.5
410
215
78.4
465
310
112.0
B=1
B=4
B=8
B=16

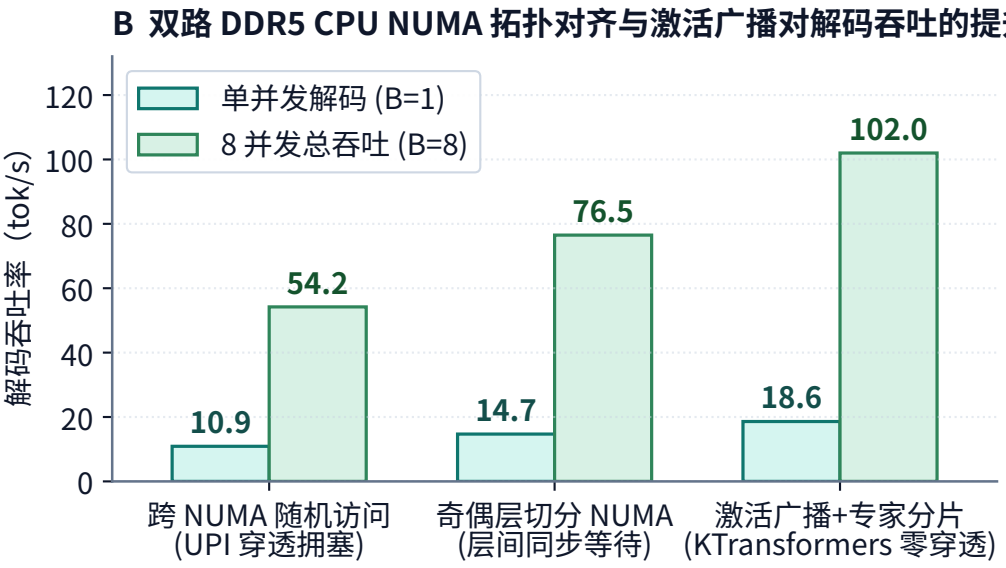
B 双路 DDR5 CPU NUMA 拓扑对齐与激活广播对解码吞吐的提升
单并发解码 (B=1)
8 并发总吞吐 (B=8)
解码吞吐率（tok/s）
0
20
40
60
80
100
120
10.9
54.2
14.7
76.5
18.6
102.0
跨 NUMA 随机访问
(UPI 穿透拥塞)
奇偶层切分 NUMA
(层间同步等待)
激活广播+专家分片
(KTransformers 零穿透)