A. 整份串行 vs 按层流水 KV 交接

传统整份串行交接：
32/36 层算完再发 1~1.125 GiB

串行暴露交接耗时：
25 GB/s 下等待 42.95~48.32 ms

按层流水异步 RDMA 交接：
算完第 l 层即发 32 MiB KV

前 L-1 层传输隐藏于计算中
仅末层 1.35 ms 暴露于 TTFT

B. 暴露延迟压缩与双轨拥塞回退

计算掩盖判据：
单层计算 $t_{P,l} >=$ 传输 $t_{X,l}$

双轨 RDMA 负载分担：
奇偶层交错走 Rail-0 / Rail-1

网络拥塞或接收槽满回退：
合并 k 层聚批发送防队头阻塞

细粒度完成位图 (Bitmask)：
全层置 1 后 D 池即启动首步