A. Mooncake KV 中心解耦池

Conductor 全局调度器：
维护全局块哈希目录与水位

多级 KV 池 (HBM+DRAM+NVMe)
RDMA 异步存取与前缀路由

vLLM 0.24 / Dynamo 1.3 边界：
仅 HBM 发事件，防混合脏读

长上下文吞吐提升最高 525%
SLO 下承载力显著优于共置

B. 预测性早期拒绝机制

朴素准入陷阱：仅看 P 池空闲
盲目接纳并耗费算力跑 Prefill

交接至 D 池触发未来 KV 耗尽：
在途生成增长致 OOM 驱逐重算

Mooncake 预测性准入判据：
预估未来窗 [t, t+T] 的 KV 水位

超上限 M_D_max 则 P 前拒绝
或延后准入，零无效 Prefill