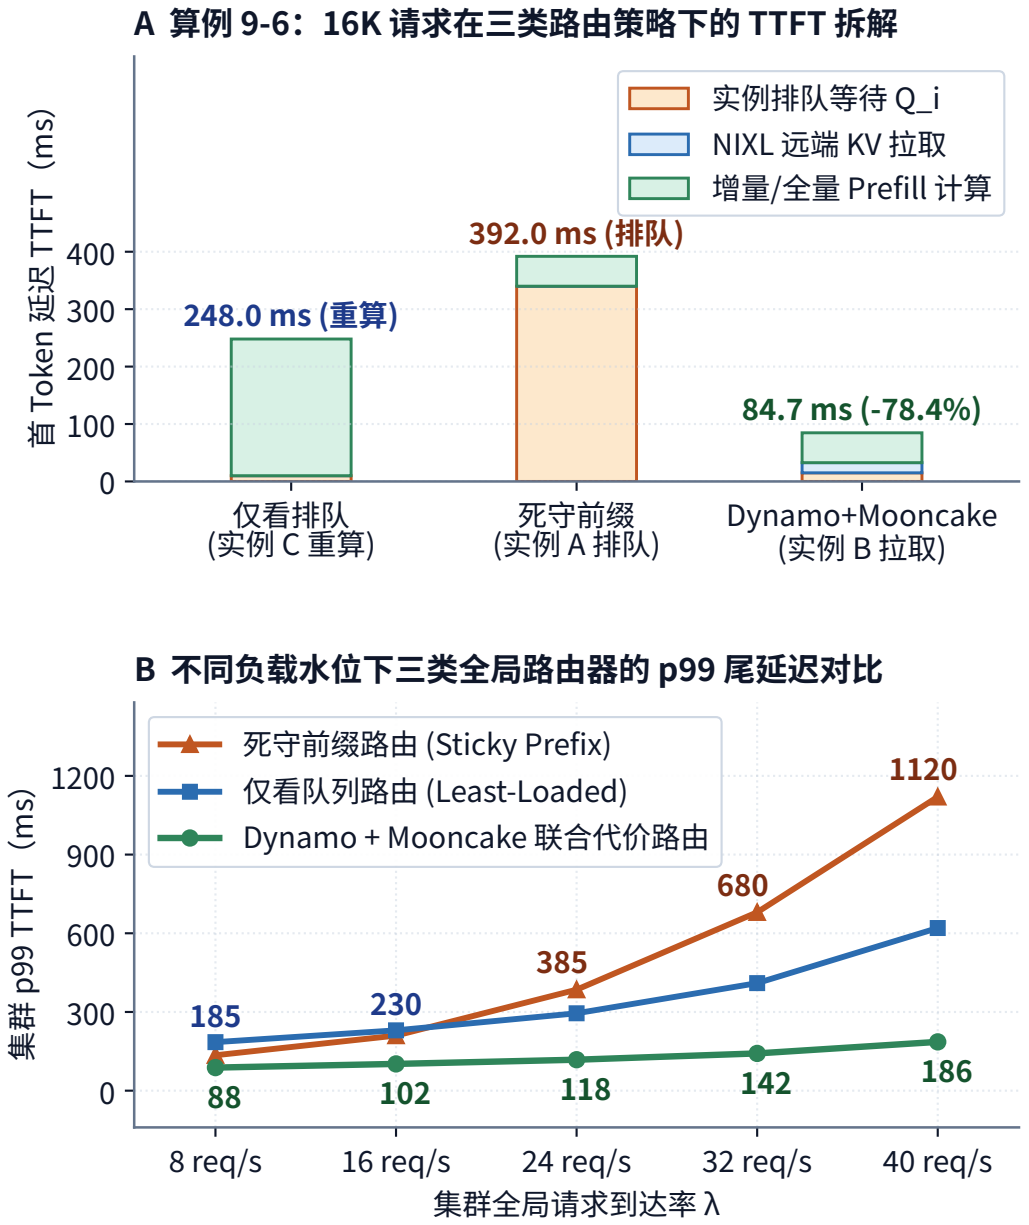
A 算例 9-6：16K 请求在三类路由策略下的 TTFT 拆解
首 Token 延迟 TTFT（ms）
0
100
200
300
400
实例排队等待 Q_i
NIXL 远端 KV 拉取
增量/全量 Prefill 计算
248.0 ms (重算)
392.0 ms (排队)
84.7 ms (-78.4%)
仅看排队
(实例 C 重算)
死守前缀
(实例 A 排队)
Dynamo+Mooncake
(实例 B 拉取)
B 不同负载水位下三类全局路由器的 p99 尾延迟对比
集群 p99 TTFT（ms）
0
300
600
900
1200
死守前缀路由 (Sticky Prefix)
仅看队列路由 (Least-Loaded)
Dynamo + Mooncake 联合代价路由
185
230
385
680
1120
88
102
118
142
186
8 req/s
16 req/s
24 req/s
32 req/s
40 req/s
集群全局请求到达率 λ