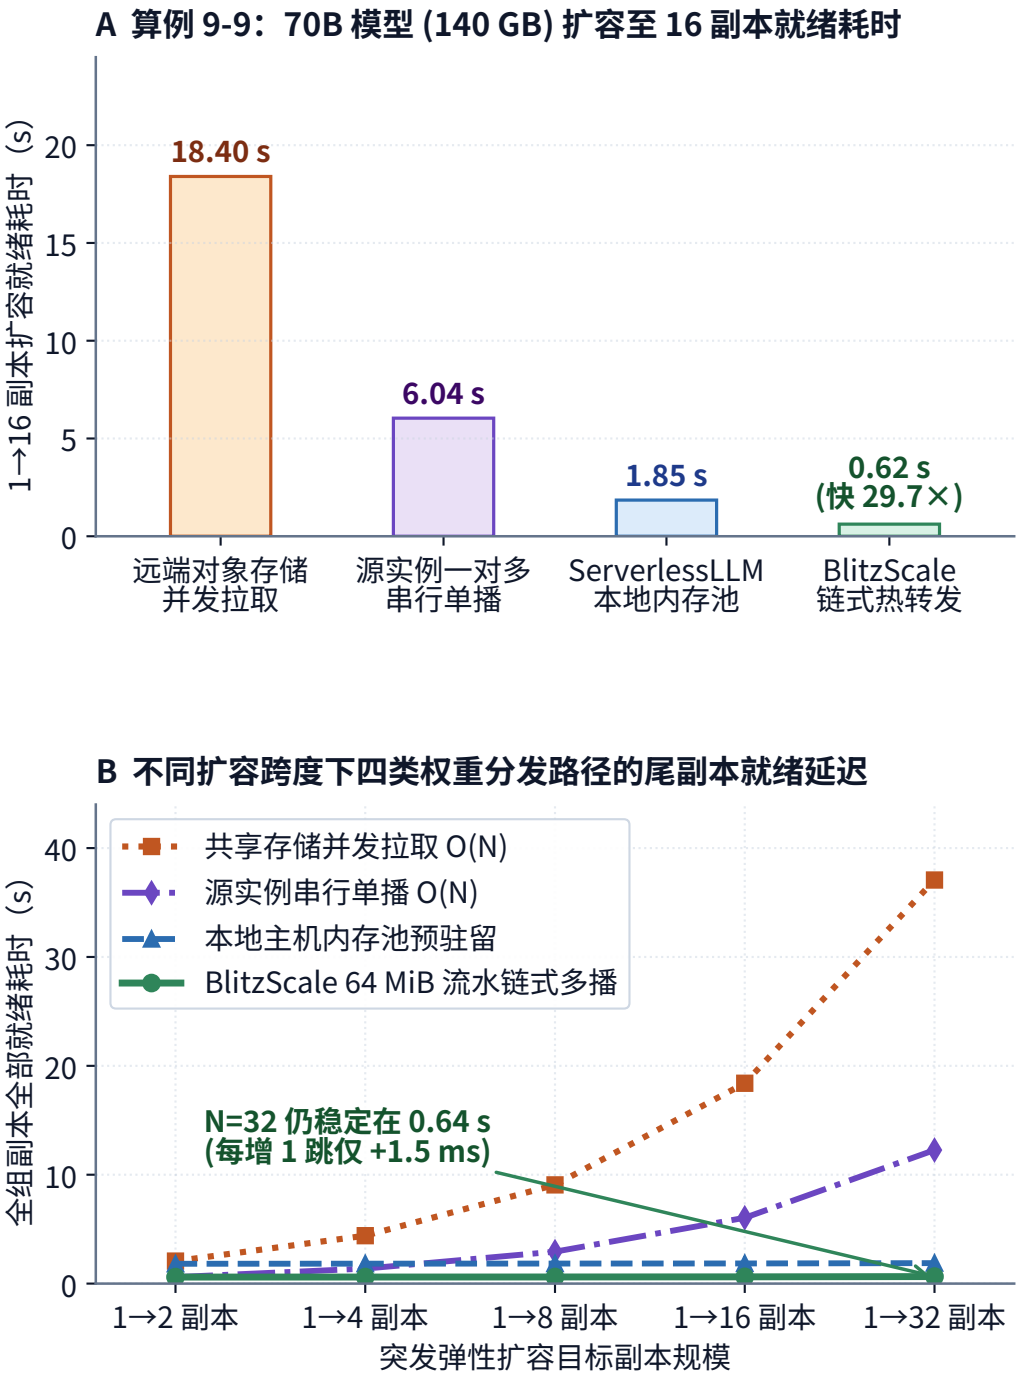
A 算例 9-9：70B 模型 (140 GB) 扩容至 16 副本就绪耗时
1→16 副本扩容就绪耗时（s）
0
5
10
15
20
18.40 s
6.04 s
1.85 s
0.62 s
(快 29.7×)
远端对象存储
并发拉取
源实例一对多
串行单播
ServerlessLLM
本地内存池
BlitzScale
链式热转发
B 不同扩容跨度下四类权重分发路径的尾副本就绪延迟
全组副本全部就绪耗时（s）
0
10
20
30
40
共享存储并发拉取 O(N)
源实例串行单播 O(N)
本地主机内存池预驻留
BlitzScale 64 MiB 流水链式多播
N=32 仍稳定在 0.64 s
(每增 1 跳仅 +1.5 ms)
1→2 副本
1→4 副本
1→8 副本
1→16 副本
1→32 副本
突发弹性扩容目标副本规模