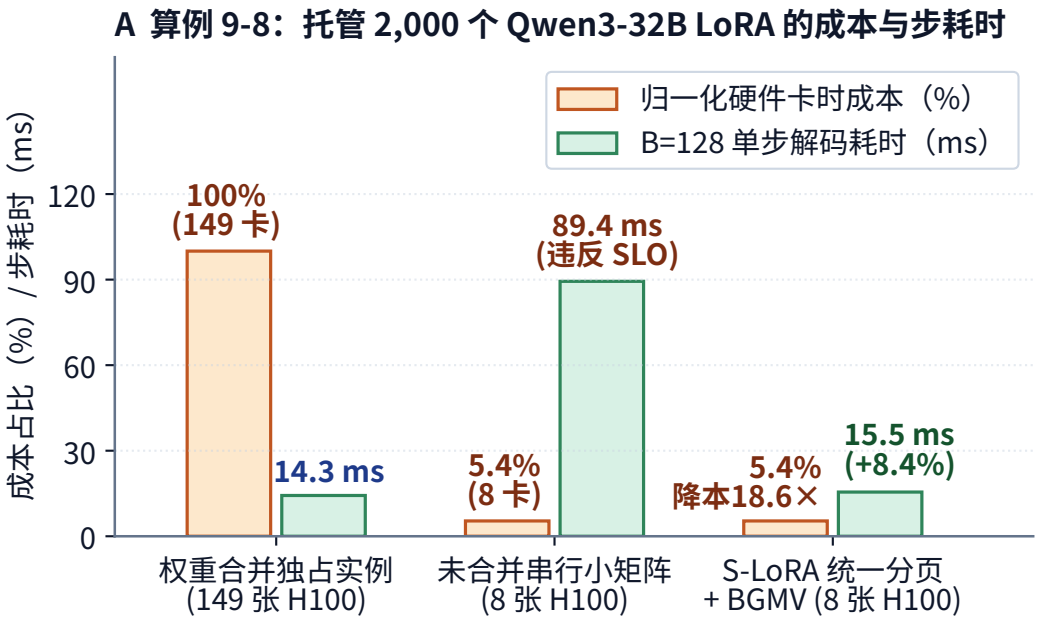
A 算例 9-8：托管 2,000 个 Qwen3-32B LoRA 的成本与步耗时
归一化硬件卡时成本（%）
B=128 单步解码耗时（ms）
成本占比（%）/ 步耗时（ms）
120
90
60
30
0
100%
(149 卡)
14.3 ms
89.4 ms
(违反 SLO)
5.4%
(8 卡)
5.4%
降本18.6×
15.5 ms
(+8.4%)
权重合并独占实例
(149 张 H100)
未合并串行小矩阵
(8 张 H100)
S-LoRA 统一分页
+ BGMV (8 张 H100)

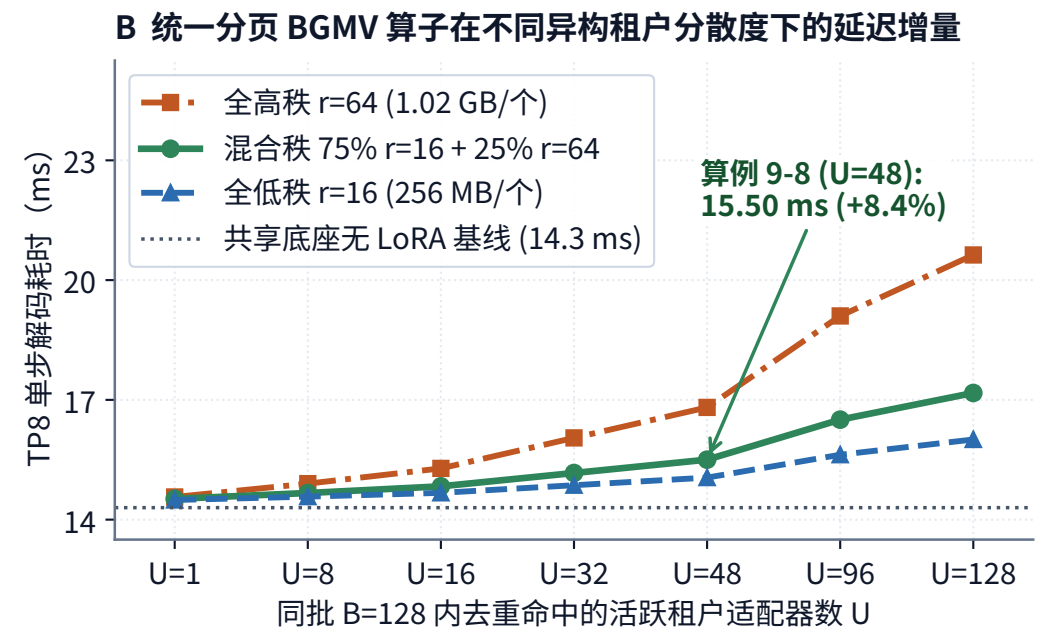
B 统一分页 BGMV 算子在不同异构租户分散度下的延迟增量
全高秩 r=64 (1.02 GB/个)
混合秩 75% r=16 + 25% r=64
全低秩 r=16 (256 MB/个)
共享底座无 LoRA 基线 (14.3 ms)
算例 9-8 (U=48):
15.50 ms (+8.4%)
TP8 单步解码耗时（ms）
23
20
17
14
U=1
U=8
U=16
U=32
U=48
U=96
U=128
同批 B=128 内去重命中的活跃租户适配器数 U