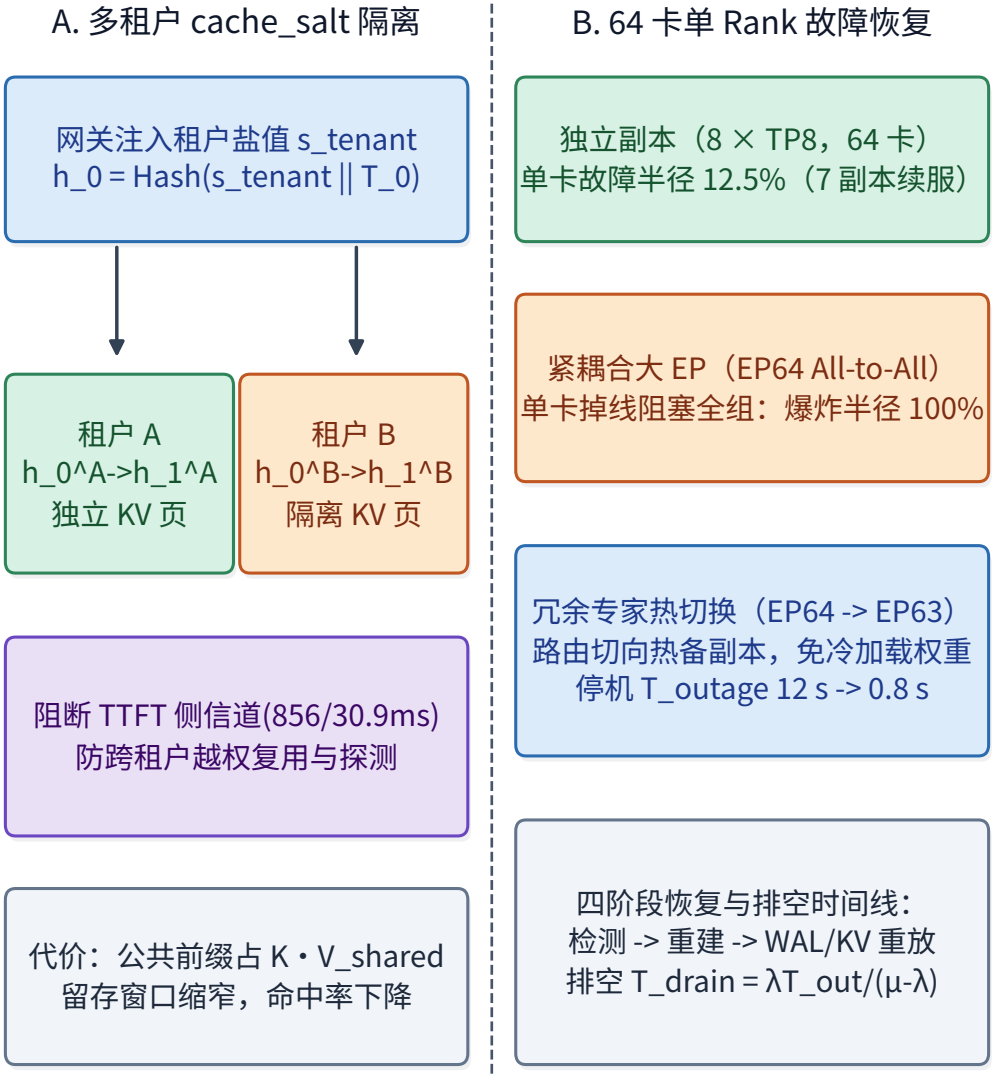
A. 多租户 cache_salt 隔离
网关注入租户盐值 s_tenant
h_0 = Hash(s_tenant || T_0)
租户 A
h_0^A->h_1^A
独立 KV 页
租户 B
h_0^B->h_1^B
隔离 KV 页
阻断 TTFT 侧信道(856/30.9ms)
防跨租户越权复用与探测
代价：公共前缀占 K・V_shared
留存窗口缩窄，命中率下降
B. 64 卡单 Rank 故障恢复
独立副本（8 × TP8，64 卡）
单卡故障半径 12.5%（7 副本续服）
紧耦合大 EP（EP64 All-to-All）
单卡掉线阻塞全组：爆炸半径 100%
冗余专家热切换（EP64 -> EP63）
路由切向热备副本，免冷加载权重
停机 T_outage 12 s -> 0.8 s
四阶段恢复与排空时间线：
检测 -> 重建 -> WAL/KV 重放
排空 T_drain = λT_out/(μ-λ)