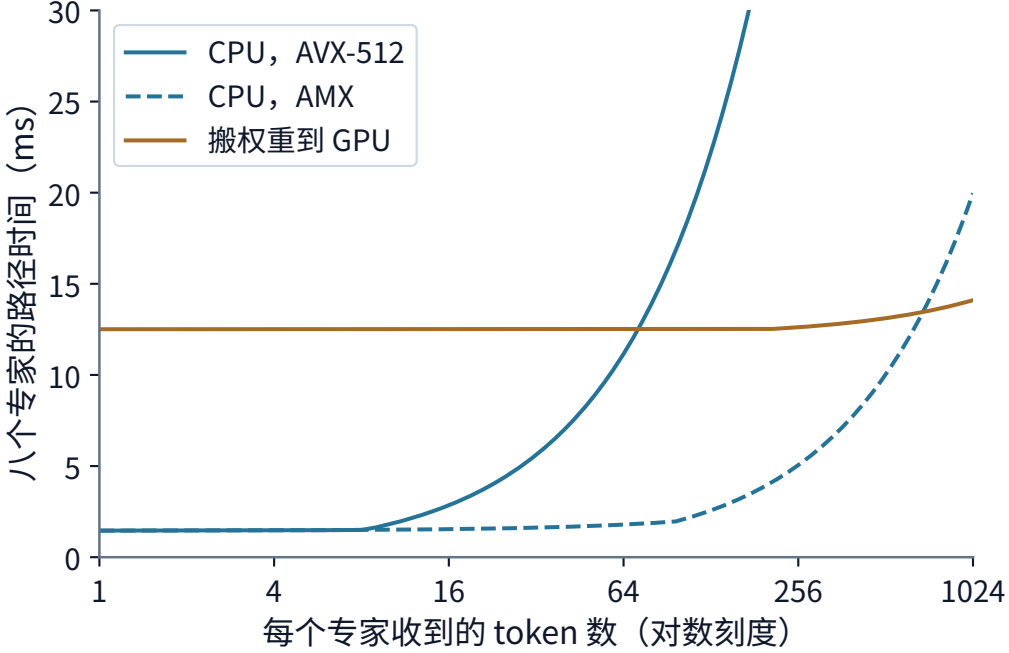
CPU，AVX-512
CPU，AMX
搬权重到 GPU
八个专家的路径时间（ms）
每个专家收到的 token 数（对数刻度）
0
5
10
15
20
25
30
1
4
16
64
256
1024