① 共置不分块：8192 token prefill 独占 856 ms，在途请求停顿约 16 步

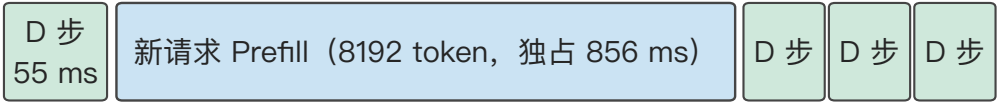

在途 32 条 decode 请求被阻塞 856 ms（输出间隔骤增）

② 共置分块捎带：利用每步 decode 算力空隙（50.9 ms）捎带约 488 token

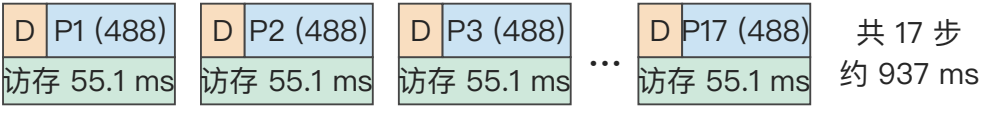

橙：D 矩阵计算 4.2 ms　蓝：分块 P 矩阵计算　绿：D 显存读取 55.1 ms
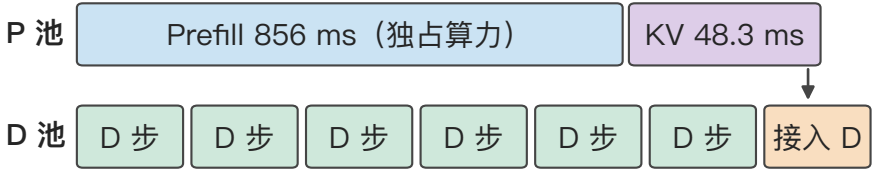
③ PD 分离：P 池专职处理输入，D 池按独立节奏连续生成