① 先算完再生成：长 Prefill 阻塞在途 Decode，单步算力闲置

② 分块 Prefill 捎带：在 55.1 ms 访存窗口内顺带算约 488 token
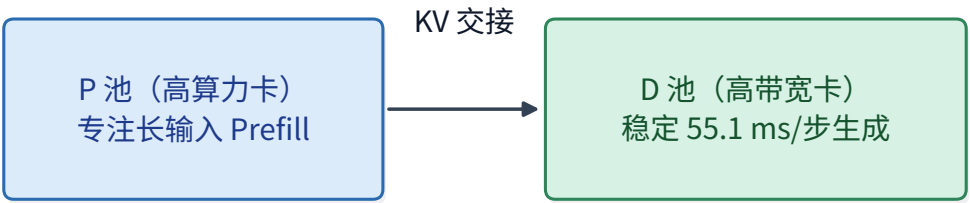
③ 严苛延迟下的 PD 分离：两池解耦，各司其职互不阻塞