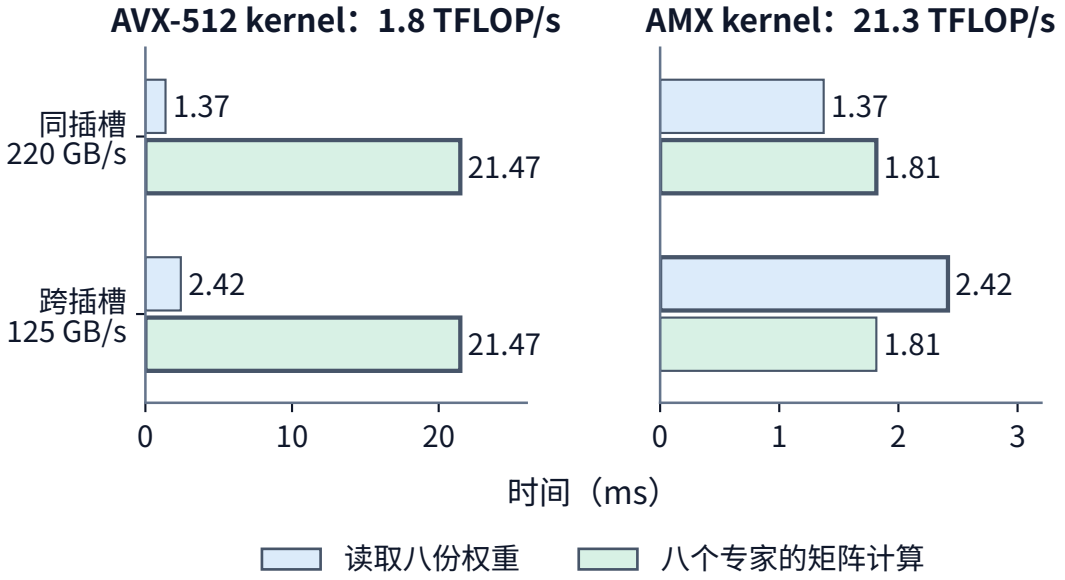
AVX-512 kernel：1.8 TFLOP/s
AMX kernel：21.3 TFLOP/s
同插槽
220 GB/s
跨插槽
125 GB/s
1.37
21.47
2.42
21.47
1.37
1.81
2.42
1.81
0
10
20
0
1
2
3
时间（ms）
读取八份权重
八个专家的矩阵计算