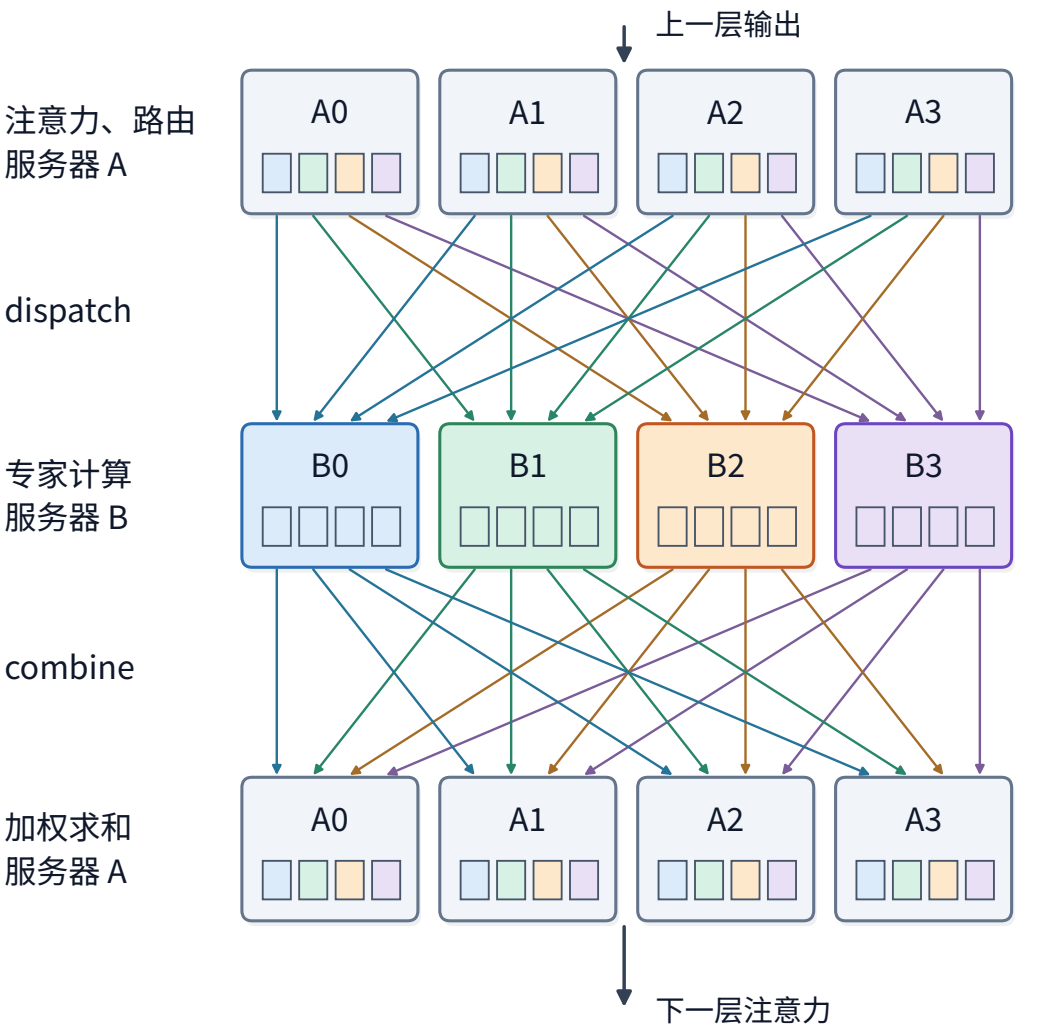
上一层输出
注意力、路由
服务器 A
A0
A1
A2
A3
dispatch
专家计算
服务器 B
B0
B1
B2
B3
combine
加权求和
服务器 A
A0
A1
A2
A3
下一层注意力