同为 512 次分派（19.3 GFLOPs）

8 专家
× 64 行

集中路由
权重读 288 MiB
主存耗时 1.37 ms

均匀覆盖：128 专家 × 4 行

权重读 4.5 GiB（22.0 ms，16 倍）

有效计算量相同
活跃专家数决定权重读取量

随机路由活跃专家数与权重读取

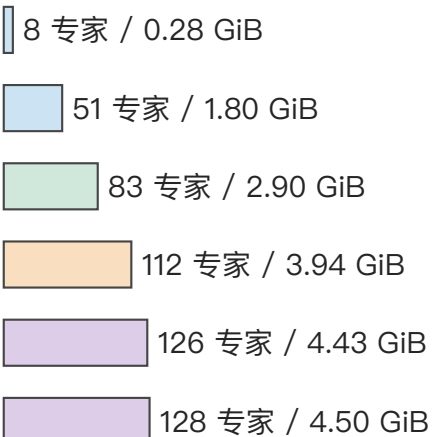

M≥64 接近 128 专家上限
后续新增行复用已读权重