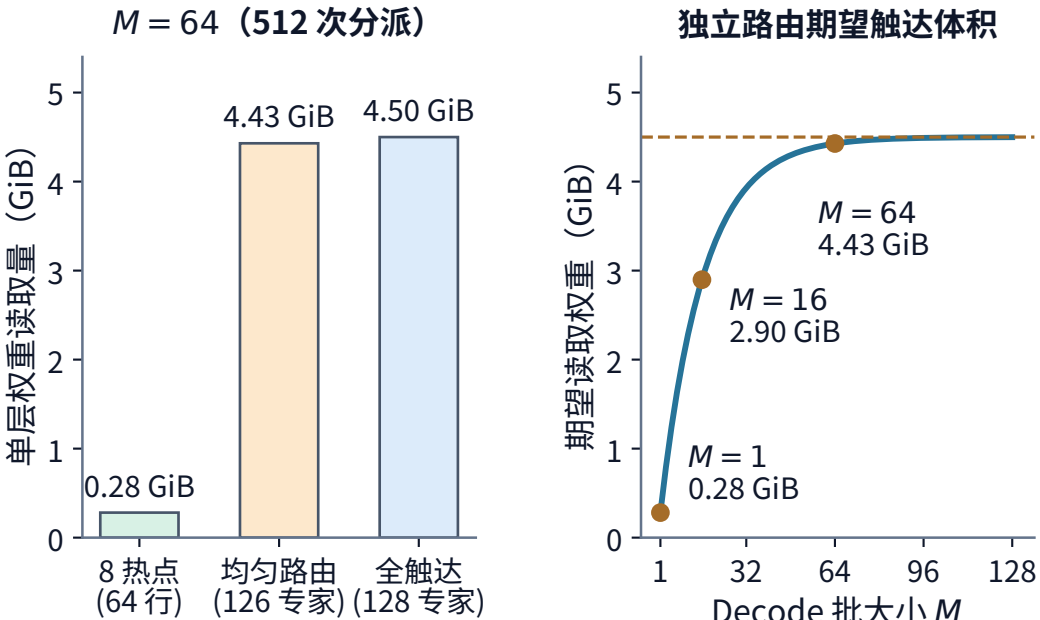
M = 64（512 次分派）
单层权重读取量（GiB）
0
1
2
3
4
5
0.28 GiB
4.43 GiB
4.50 GiB
8 热点
(64 行)
均匀路由
(126 专家)
全触达
(128 专家)
独立路由期望触达体积
期望读取权重（GiB）
M = 64
4.43 GiB
M = 16
2.90 GiB
M = 1
0.28 GiB
1
32
64
96
128
Decode 批大小 M