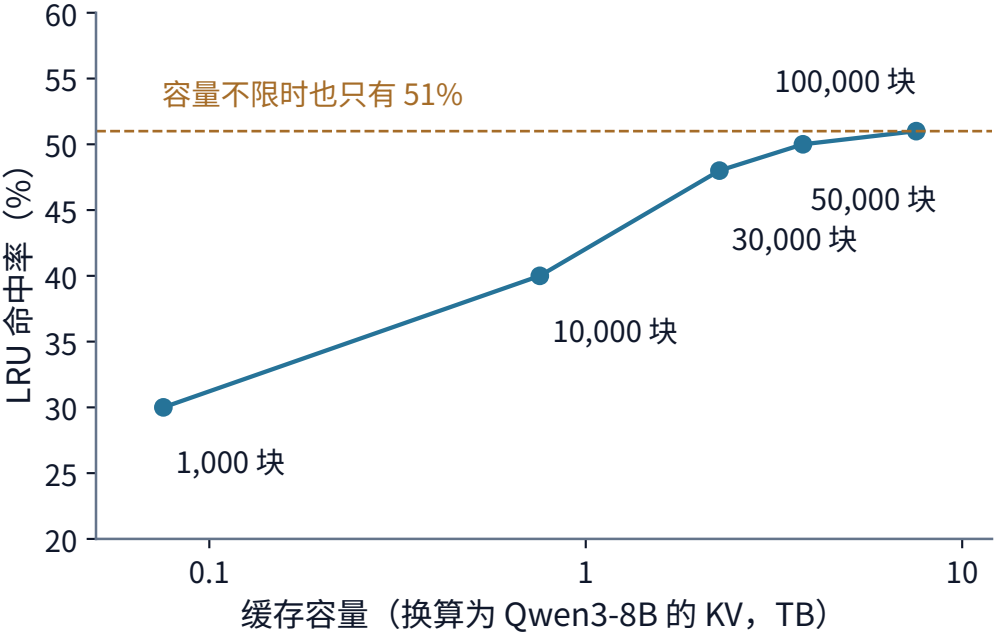
60
55
50
45
40
35
30
25
20
LRU 命中率（%）
容量不限时也只有 51%
100,000 块
50,000 块
30,000 块
10,000 块
1,000 块
0.1
1
10
缓存容量（换算为 Qwen3-8B 的 KV，TB）