传输开始：两端都占用完整空间

Qwen3-8B，GQA

DeepSeek-V3，紧凑 MLA

数据复制中；方框宽度按字节数比例