A. 串行 vs 单设备槽 vs 双缓冲 (I20)

8 块 × 64 MiB BF16 激活张量
准备 1ms / H2D 2.604ms / 算 4ms

① 同步串行 (1 主机+1 设备槽)
8 × 7.604 = 60.833 ms

② 单设备槽 (2 主机+1 设备槽)
DMA 等计算完：53.833 ms

③ 乒乓双槽 (2 主机+2 设备槽)
7.604 + 7×4 = 35.604 ms (1.71×)

B. 缓冲区复用约束与链路降级翻转

事件同步与安全复用边界：
主机槽等 DMA；设备槽等计算

暂存空间代价：
双侧各 2×64 = 128 MiB 缓冲

④ PCIe 降级至 12 GiB/s：
单块 H2D 升至 5.208 ms (>4ms)

瓶颈由计算翻转回传输：
双缓冲耗时升至 46.667 ms