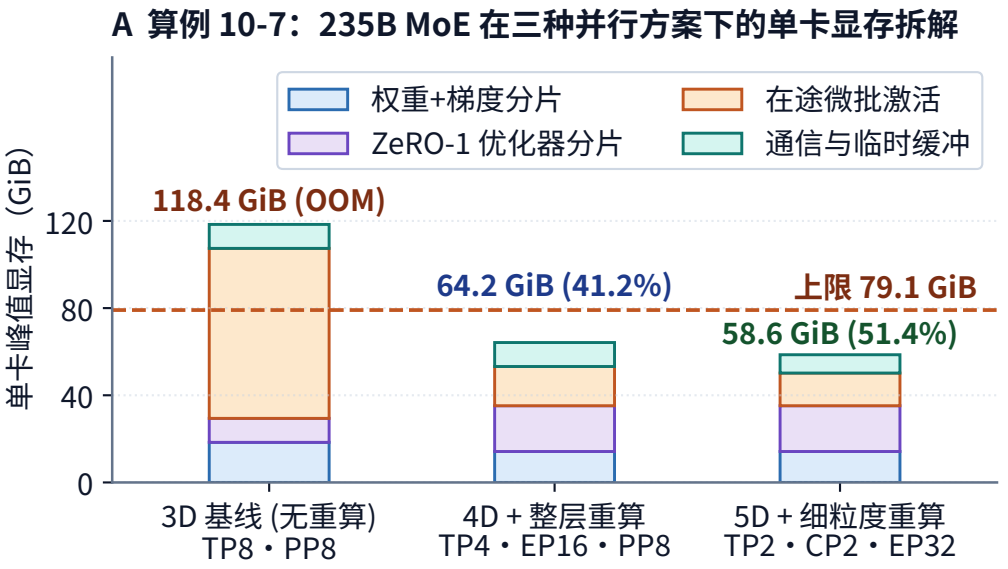
A 算例 10-7：235B MoE 在三种并行方案下的单卡显存拆解
权重+梯度分片
ZeRO-1 优化器分片
在途微批激活
通信与临时缓冲
单卡峰值显存（GiB）
0
40
80
120
118.4 GiB (OOM)
64.2 GiB (41.2%)
上限 79.1 GiB
58.6 GiB (51.4%)
3D 基线 (无重算)
TP8 • PP8
4D + 整层重算
TP4 • EP16 • PP8
5D + 细粒度重算
TP2 • CP2 • EP32

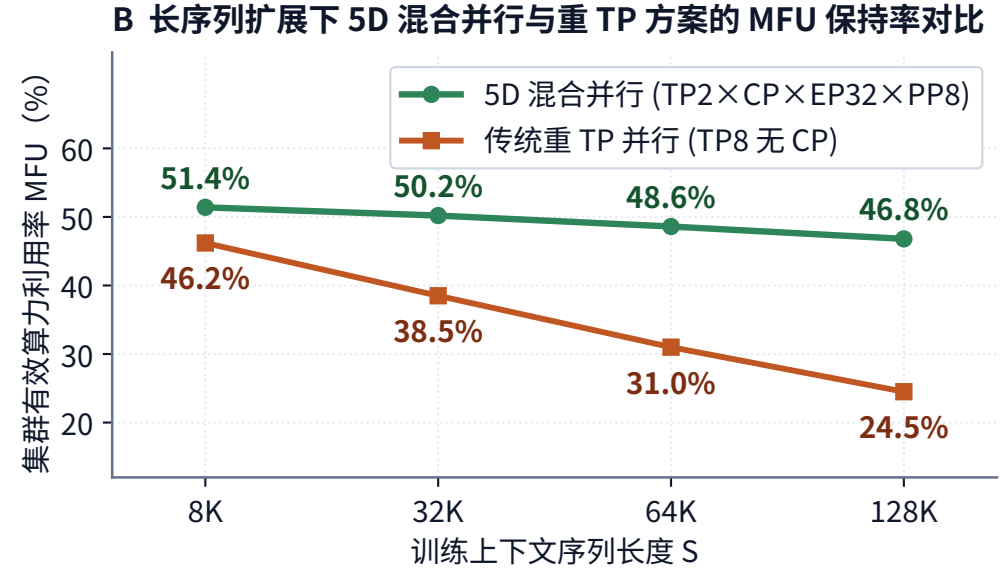
B 长序列扩展下 5D 混合并行与重 TP 方案的 MFU 保持率对比
5D 混合并行 (TP2×CP×EP32×PP8)
传统重 TP 并行 (TP8 无 CP)
集群有效算力利用率 MFU（%）
20
30
40
50
60
51.4%
50.2%
48.6%
46.8%
46.2%
38.5%
31.0%
24.5%
8K
32K
64K
128K
训练上下文序列长度 S