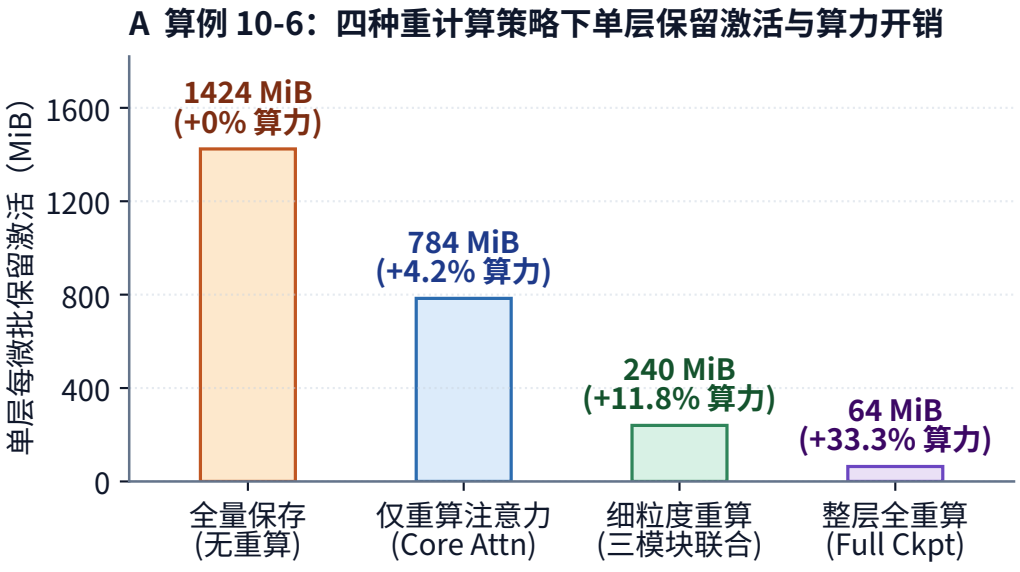
A 算例 10-6：四种重计算策略下单层保留激活与算力开销
单层每微批保留激活（MiB）
1600
1200
800
400
0
1424 MiB
(+0% 算力)
784 MiB
(+4.2% 算力)
240 MiB
(+11.8% 算力)
64 MiB
(+33.3% 算力)
全量保存
(无重算)
仅重算注意力
(Core Attn)
细粒度重算
(三模块联合)
整层全重算
(Full Ckpt)

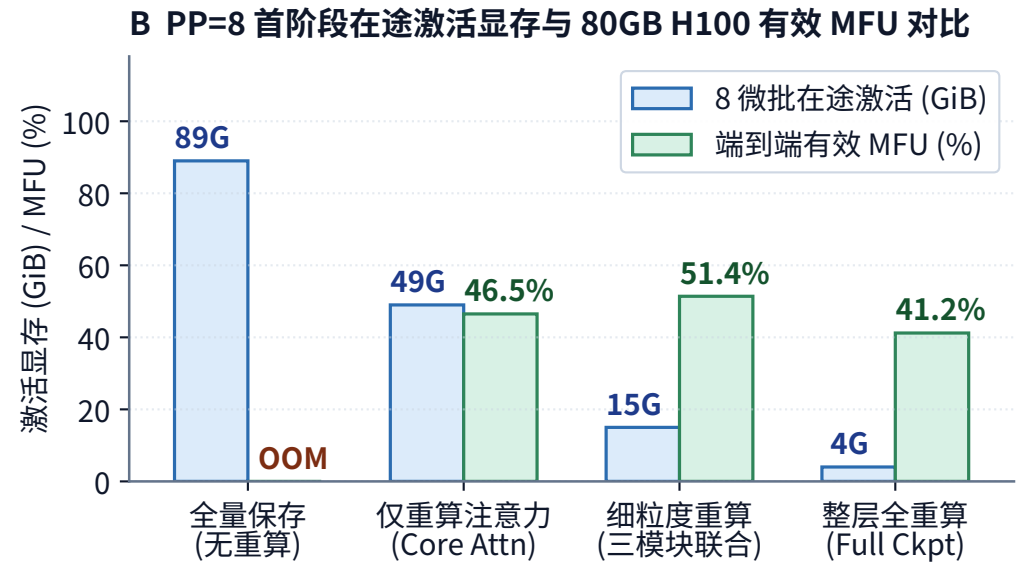
B PP=8 首阶段在途激活显存与 80GB H100 有效 MFU 对比
激活显存 (GiB) / MFU (%)
100
80
60
40
20
0
8 微批在途激活 (GiB)
端到端有效 MFU (%)
89G
OOM
49G
46.5%
15G
51.4%
4G
41.2%
全量保存
(无重算)
仅重算注意力
(Core Attn)
细粒度重算
(三模块联合)
整层全重算
(Full Ckpt)