A. SGLang 热更新六阶段职责边界

① 请求进入与 ② 暂停生成
读锁放行；is_pause 挂起/撤回

③ 提交更新与 ④ 汇总 all(success)
磁盘/张量写锁，IPC/分布式无锁

⑤ 发布管理信息（仅全成功生效）
更新 model_path 并递增版本号

⑥ 恢复生成（不查前序成败）
continue_generation 须显式调用

B. [成功,成功,失败,成功] 失败边界

四分片返回 [T, T, F, T]：
all(success)=False，拒发新版本号

就地修改 (load_weights) 无回滚：
分片 1/2/4 新权重，分片 3 半成品

投机解码 (EAGLE) 非原子更新：
target 成功而 draft 失败致失配

恢复正道：禁直接恢复生成
须统一下发重载旧权重并清空 KV