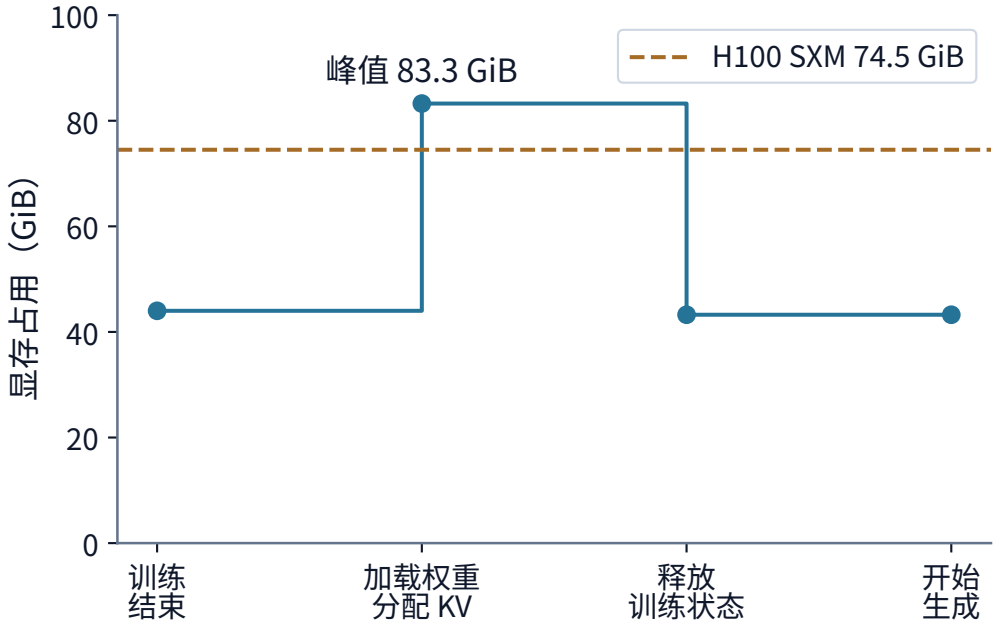
100
80
60
40
20
0
显存占用（GiB）
峰值 83.3 GiB
H100 SXM 74.5 GiB
训练
结束
加载权重
分配 KV
释放
训练状态
开始
生成