A. 算力波谷与 Batch API 填谷

24×7 预留集群刚性折旧：
B200 长租 6.79 美元/卡时
夜间在线波谷大量卡时空转

异步 Batch API（24h 窗口）：
零售牌价打 5 折（50% 折扣）
剥离实时 TTFT / TPOT 约束

物理填谷收益（夜间满批）：
夜间拼成最大批次满载运行
仅付增量电费即可回收折旧

自建 vs 按量平衡点：
预留实例需 >78.6% 利用率
单会话（batch=1）宜用 API

B. 双模型缓存路由可行域

小模型 A vs 旗舰模型 B：
B 牌价高但思考精炼（100 词）
通过率 98% vs 80%（门槛 75%）

成本反超交点 h_cost：
Claude 牌价：$h \geqslant 79.52\%$
双模型基准：$h \geqslant 84.93\%$

叠加 6 s 交付期限门槛：
B 命中 4 s 达标、未中 12 s
$0.98h \geqslant 0.90 \Rightarrow h \geqslant 91.84\%$

两级级联路由：
$E[C] = c_r + c_S + r \cdot c_L(h_L)$
跨模型不可直接共享 KV 块