A. CuMemMap 虚实地址解耦
预留虚拟地址 V_w + V_kv
绑定 CUDA Graph 指针不变
休眠：cuMemUnmap 物理页
释放 112 GB (97%) HBM
训练期：FSDP2 独占 112 GB
推理仅留 1.2 GB 壳上下文
唤醒：cuMemMap 映射新页
免重编图 (省 12.0 s)
B. Sleep Level 1 / 2 切换耗时对比
传统销毁冷重启：38.0 s
读权重 22 s + 重编图 12 s
Sleep L1 (卸载至主机内存)
PCIe 往返 2.32 s (唤醒 1.18 s)
Sleep L2 (就地丢弃旧权重)
休眠 25 ms + 唤醒 0.455 s
RL 训推同卡混部净收益：
L2 提速 83.5×，省 37.5 s