A. 双模型成本反超点 (h > 84.93%)

模型 A (廉价啰嗦)：p_A = 0.80
产 2000 词，恒 10s 超期

模型 B (旗舰精炼)：p_B = 0.98
标价 2× 但仅产 300 词，4s/12s

期望合格成本反超点：
h > 84.93% 时 B 成本更省

反直觉结论：高前缀命中率下
2× 标价旗舰单任务更省

B. 6s SLO 与双约束可行域 (91.84%)

约束 1 (6 s 期限)：A 10s 出局
B 仅在命中 (4s ⩽ 6s) 达标

约束 2 (联合合格率 ⩾ 90%)：
$p_B \times h = 0.98\, h \geqslant 0.90$

双约束可行域下界：
$h \geqslant 45/49 \approx 91.84\%$

路由策略：亲和性哈希保命中
$h \geqslant 91.84\%$ 兼得低价与合规