A. 批训练控制面 (Kueue/Volcano)
成组准入 (minAvailable)
全员就绪分配，防半数死锁
拓扑亲和放置 (TAS)
优先装箱 NVL72 与同叶脊
层级配额借用 (Cohort)
闲置训练配额出借离线评测
SkyPilot 跨云异构经纪
联合单价/抢占/出网费寻优
B. 推理控制面 (llm-d/AIBrix)
Envoy + ExtProc 推理网关
替代轮询，微秒级状态路由
KV 前缀树命中感知打分
α・Hit_KV - β・Queue_Load
PD 分离与 VTC 时钟准入
w_in L_in + w_out L_out
潮汐弹性与合成数据填谷
闲时回收算力生产蒸馏语料