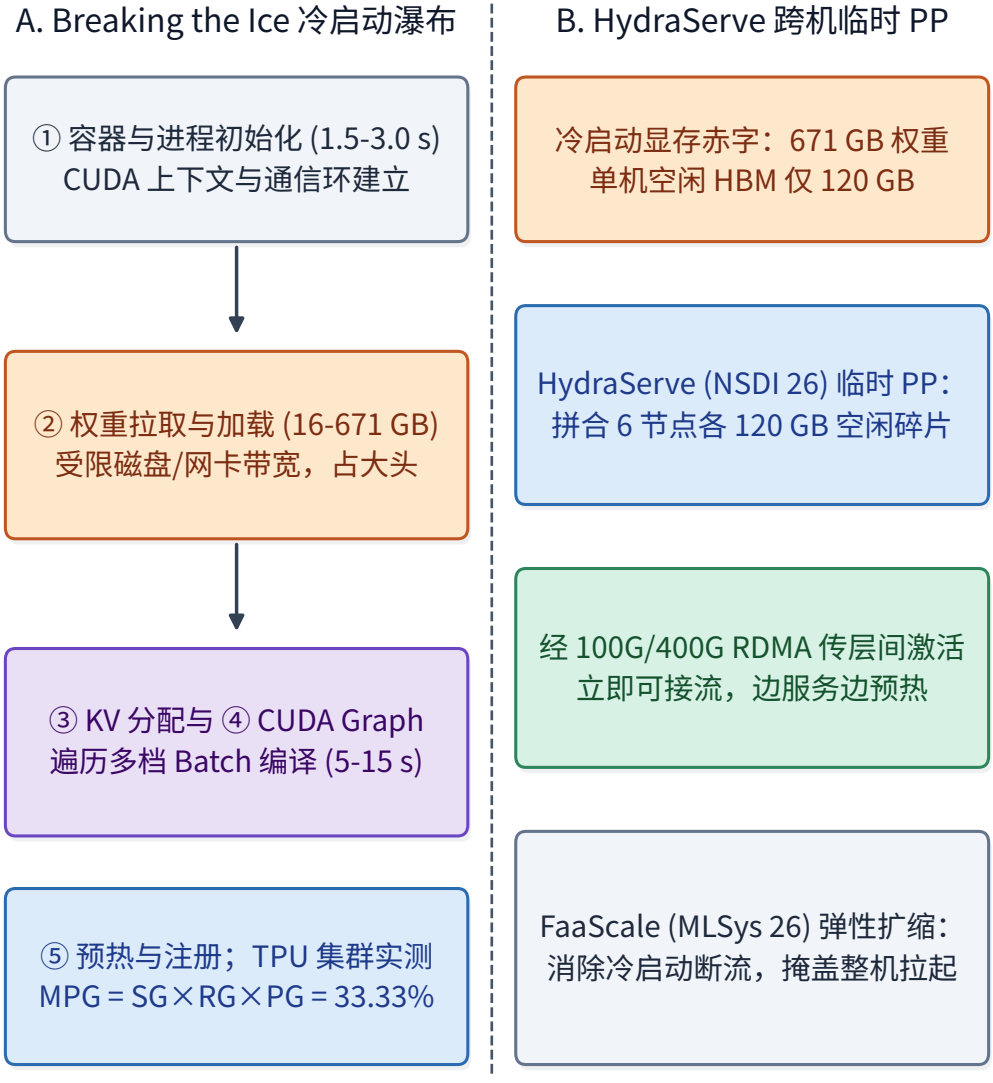
A. Breaking the Ice 冷启动瀑布
① 容器与进程初始化 (1.5-3.0 s)
CUDA 上下文与通信环建立
② 权重拉取与加载 (16-671 GB)
受限磁盘/网卡带宽，占大头
③ KV 分配与 ④ CUDA Graph
遍历多档 Batch 编译 (5-15 s)
⑤ 预热与注册；TPU 集群实测
MPG = SG×RG×PG = 33.33%
B. HydraServe 跨机临时 PP
冷启动显存赤字：671 GB 权重
单机空闲 HBM 仅 120 GB
HydraServe (NSDI 26) 临时 PP：
拼合 6 节点各 120 GB 空闲碎片
经 100G/400G RDMA 传层间激活
立即可接流，边服务边预热
FaaScale (MLSys 26) 弹性扩缩：
消除冷启动断流，掩盖整机拉起