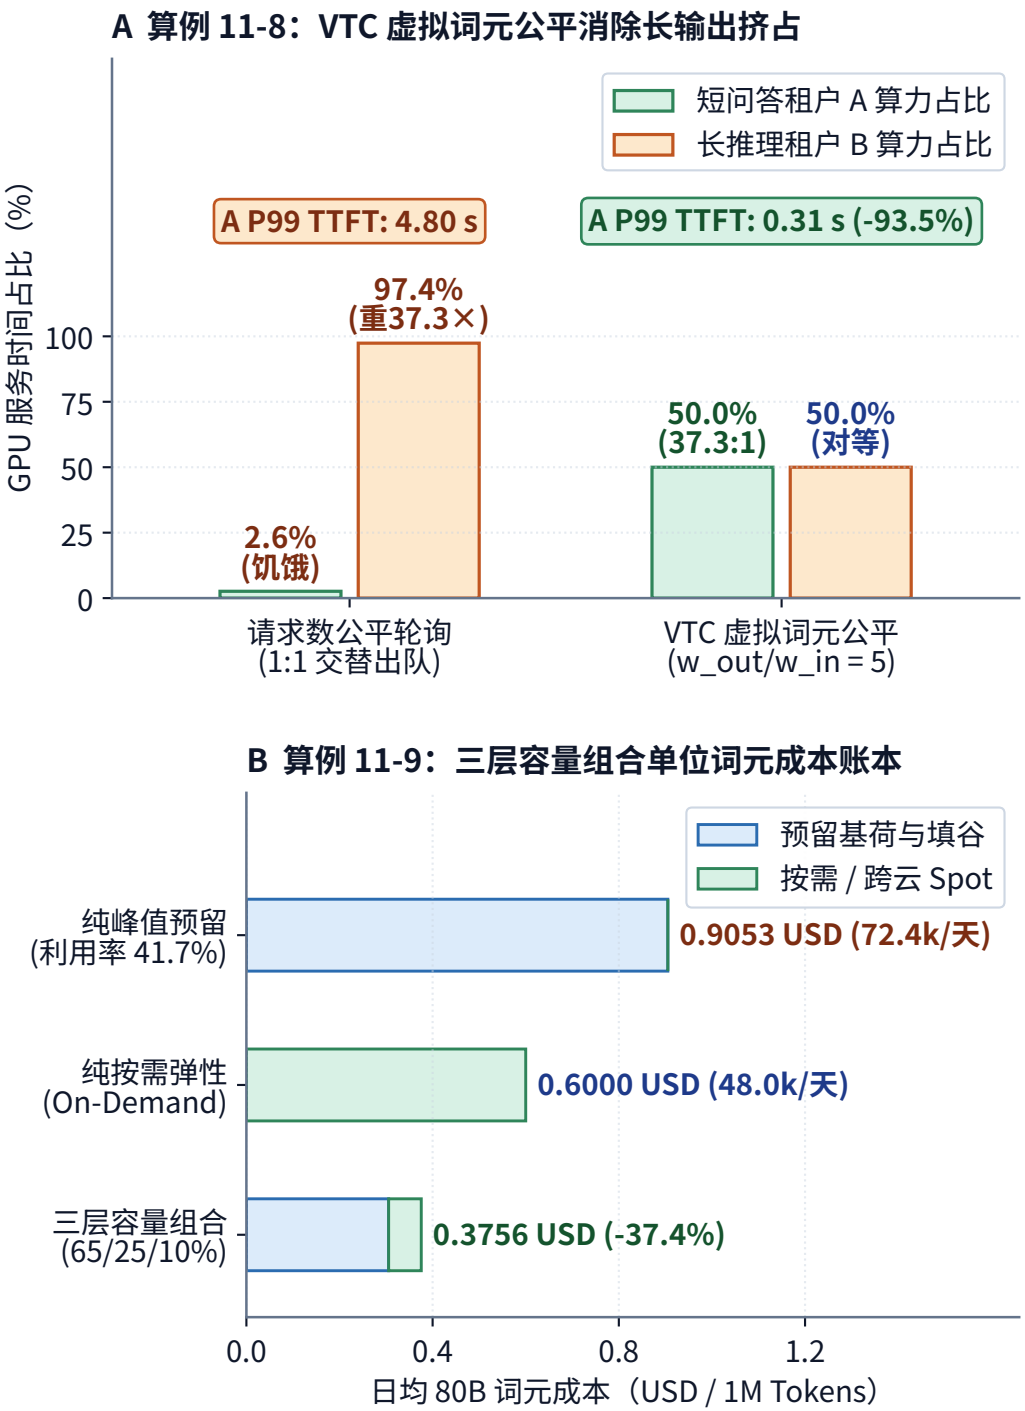
A 算例 11-8：VTC 虚拟词元公平消除长输出挤占
短问答租户 A 算力占比
长推理租户 B 算力占比
GPU 服务时间占比（%）
A P99 TTFT: 4.80 s
A P99 TTFT: 0.31 s (-93.5%)
97.4%
(重37.3×)
2.6%
(饥饿)
50.0%
(37.3:1)
50.0%
(对等)
100
75
50
25
0
请求数公平轮询
(1:1 交替出队)
VTC 虚拟词元公平
(w_out/w_in = 5)
B 算例 11-9：三层容量组合单位词元成本账本
预留基荷与填谷
按需 / 跨云 Spot
纯峰值预留
(利用率 41.7%)
0.9053 USD (72.4k/天)
纯按需弹性
(On-Demand)
0.6000 USD (48.0k/天)
三层容量组合
(65/25/10%)
0.3756 USD (-37.4%)
0.0
0.4
0.8
1.2
日均 80B 词元成本（USD / 1M Tokens）