A. Weave 多作业 CPU-GPU 交错

互补 RL 作业共享同一对资源池
Rollout 与训练阶段反相交错

休眠阶段状态卸载至主机 DRAM
热切换仅 5 s（冷加载 45 s）

周期下界与内存容量红线：
双作业驻留须核验 1 TiB 上限

OSDI 26 实测：消除双池空置
大幅提升多租户集群有效产出

B. RLBoost 抢占实例弹性卸载

主组 8×H100 ($83.79/h) + 6 组
2×H100 Spot 实例 ($5.32/h)

新实例轮内即时拉取权重参战
共享 200G 出口下界 3.93 s

抢占迁移：保留已生成输出前缀
换实例重做 Prefill（组内截齐）

成本盈亏门槛：费率 1.381×
实测吞吐 1.5-2.0×，省 22-37%