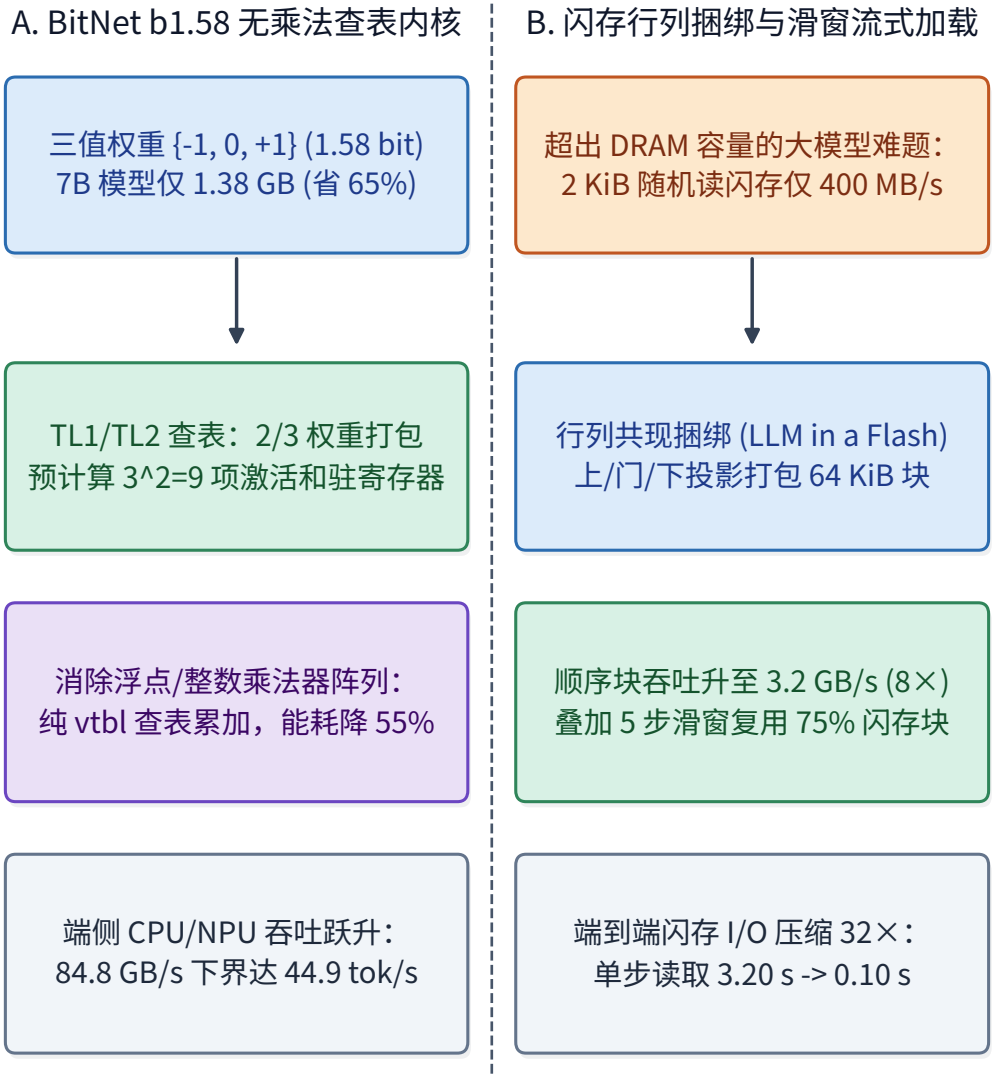
A. BitNet b1.58 无乘法查表内核
三值权重 {-1, 0, +1} (1.58 bit)
7B 模型仅 1.38 GB (省 65%)
TL1/TL2 查表：2/3 权重打包
预计算 3^2=9 项激活和驻寄存器
消除浮点/整数乘法器阵列：
纯 vtbl 查表累加，能耗降 55%
端侧 CPU/NPU 吞吐跃升：
84.8 GB/s 下界达 44.9 tok/s
B. 闪存行列捆绑与滑窗流式加载
超出 DRAM 容量的大模型难题：
2 KiB 随机读闪存仅 400 MB/s
行列共现捆绑 (LLM in a Flash)
上/门/下投影打包 64 KiB 块
顺序块吞吐升至 3.2 GB/s (8×)
叠加 5 步滑窗复用 75% 闪存块
端到端闪存 I/O 压缩 32×：
单步读取 3.20 s -> 0.10 s