A. 端侧起草 + 云端批量验证流水
端侧 1.5B 小模型本地起草
自回归生成 K 词 (12 ms/tok)
经广域网 (RTT 60 ms) 上传
云端 671B 大模型单步并行验证
单轮期望产出 (1-α^{K+1})/(1-α)
摊薄跨网 RTT 与云端前向耗时
最优步长 K* 闭式权衡：
RTT=60ms, α=0.80 时 K*=5 词
B. 本地隐私脱敏还原网关 (PII)
上云前拦截：端侧跑轻量 NER
识别姓名/卡号/密钥/IP 实体
结构化占位符替换：
映射为 [[PER_1]] 存安全区
云端大模型在脱敏上下文上推理
全链路零明文敏感数据出境
返回流式解码时本地查表还原：
兼得云端旗舰智商与端侧零泄密