A. ExecuTorch 导出与静态内存池
torch.export 捕获 ATen 图
降级为 Edge Dialect (EXIR)
静态生命周期区间分析：
峰值激活 192 -> 48 MiB (4×)
Delegate 算子分区下放
QNN / CoreML / XNNPACK
生成 .pte FlatBuffer 产物
50 KB 运行时，零动态分配
B. NPU 子图碎片化 vs. 融合委派
纯移动端 CPU 基线 (XNNPACK)
320 算子串行耗时 96.00 ms
碎片化 NPU 委派 (85% 下放)
24 次切换耗 30 ms -> 64.8 ms
算子重写单图融合 (97.5%)
仅 2 次首尾切换 (2.50 ms)
端到端延迟压降至 28.30 ms
较 CPU 提速 3.39×，省 2.29×