A. 96 GB 统一内存 vs 独立显存

M2 Max（96 GB 统一内存）：
400 GB/s，4 GiB 读 10.74 ms
M2 Pro（200 GB/s）：21.47 ms

RTX PRO 6000（96GB 显存）：
1,792 GB/s，4 GiB 读 2.40 ms
带宽达 M2 Max 的 4.48 倍

统一内存工作集边界：
CPU/GPU/OS 争抢同一物理池
受 Metal 安全工作集上限约束

独立显存边界（600 W）：
PCIe 5.0 x16 负责初始加载
96 GB ECC 显存由 GPU 独占

B. 端—边—云三维部署边界

端侧便携（M2 Max 笔记本）：
断网可用、最高隐私、数十瓦
适合单流低频交互与外出开发

附近工作站（RTX PRO 6000）：
局域网低 RTT + 4.48× 解码带宽
20 轮截图 11.0 s（快于云端）

远端云集群（H100 / B200）：
3.35–8.0 TB/s 支撑超长上下文
受广域网上行与 200 ms RTT 制约

Ollama 配对评测铁律：
剥离 load_duration 冷启动
严防 KV 缓存命中造成虚假加速