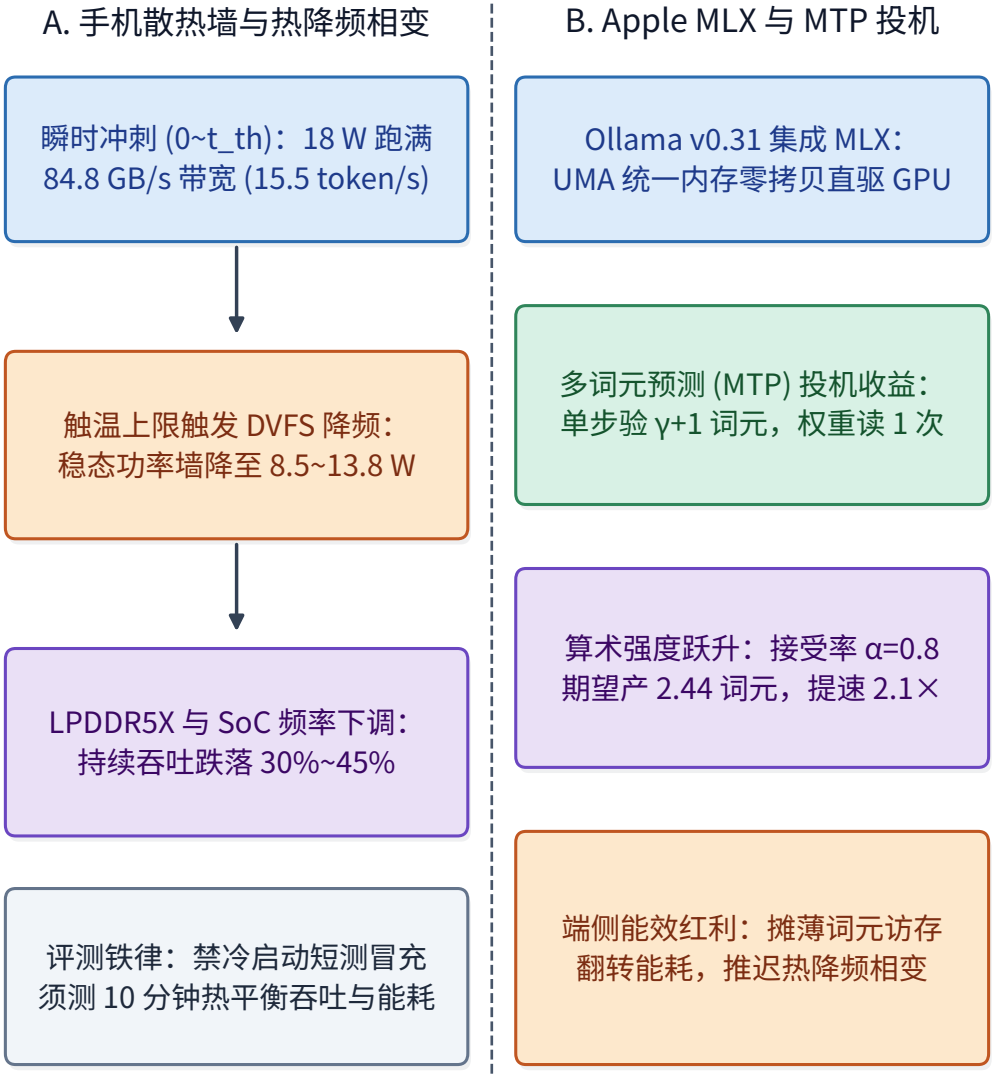
A. 手机散热墙与热降频相变
瞬时冲刺 (0~t_th)：18 W 跑满
84.8 GB/s 带宽 (15.5 token/s)
触温上限触发 DVFS 降频：
稳态功率墙降至 8.5~13.8 W
LPDDR5X 与 SoC 频率下调：
持续吞吐跌落 30%~45%
评测铁律：禁冷启动短测冒充
须测 10 分钟热平衡吞吐与能耗
B. Apple MLX 与 MTP 投机
Ollama v0.31 集成 MLX：
UMA 统一内存零拷贝直驱 GPU
多词元预测 (MTP) 投机收益：
单步验 γ+1 词元，权重读 1 次
算术强度跃升：接受率 α=0.8
期望产 2.44 词元，提速 2.1×
端侧能效红利：摊薄词元访存
翻转能耗，推迟热降频相变