A. NPU 静态分块图与填充开销

Hexagon NPU / ExecuTorch：
算子图须按固定块长 B 编译

填充浪费：L_p=513 按 B=256
切 3 块实算 768 词元 (+49.7%)

细粒度 B=128：切为 5 块
实算 640 词元（多算 127 个）

llm.npu / MLLM 异构协同：
NPU 跑 INT8 块，CPU 跑补偿

B. FlexSP 变长序列与通信

同为 8192 词元的不同分箱：
[4096,4096] vs [7168,1024]

因果注意力对数差 1.56×~2.0×
长文档配更高 SP 度数降显存

Ulysses GQA 陷阱 (Qwen3)：
先扩 KV 使载荷 12 增至 24KiB

梯度归约：按有效词元加权
(token_mean 2.75 vs 均值 2.0)