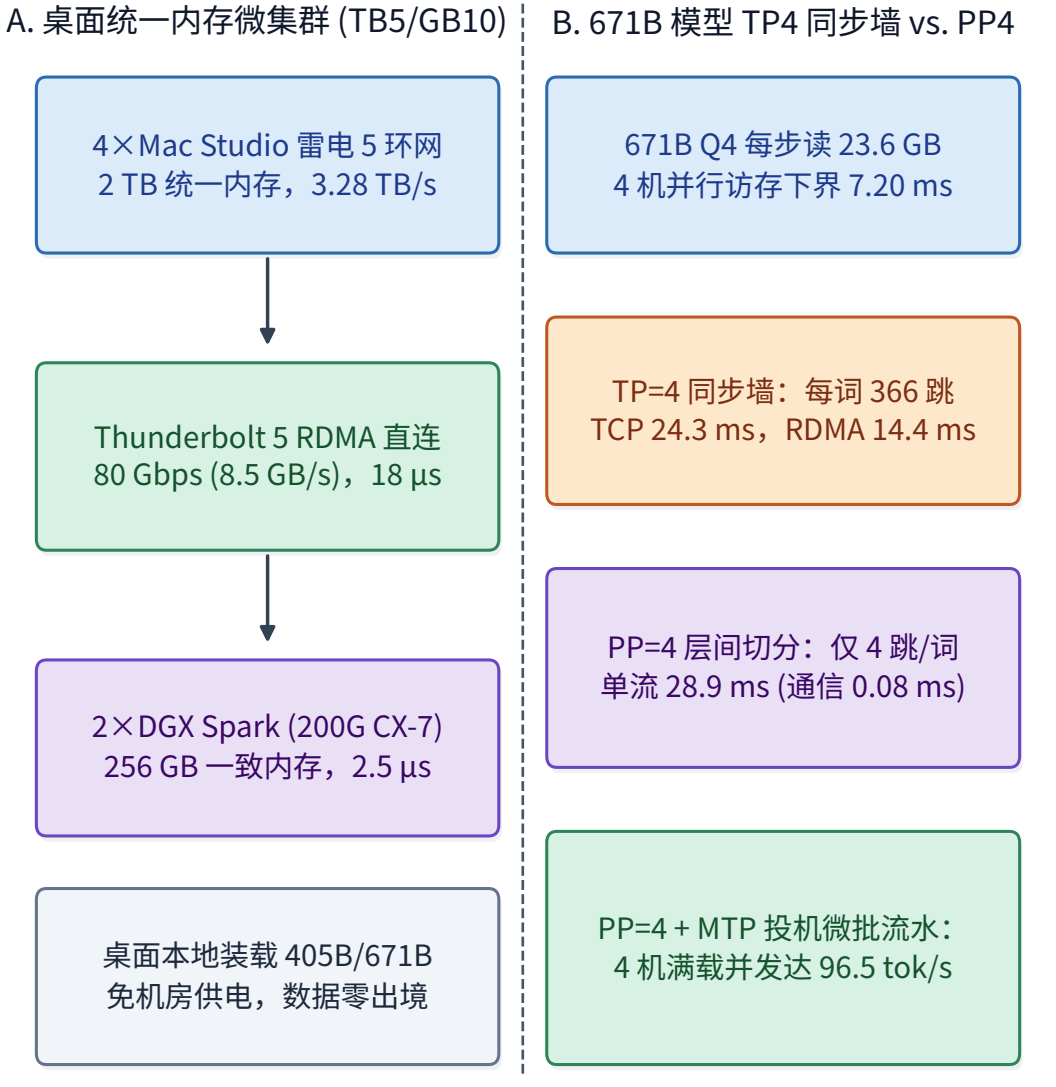
A. 桌面统一内存微集群 (TB5/GB10)
4×Mac Studio 雷电 5 环网
2 TB 统一内存，3.28 TB/s
Thunderbolt 5 RDMA 直连
80 Gbps (8.5 GB/s)，18 µs
2×DGX Spark (200G CX-7)
256 GB 一致内存，2.5 µs
桌面本地装载 405B/671B
免机房供电，数据零出境
B. 671B 模型 TP4 同步墙 vs. PP4
671B Q4 每步读 23.6 GB
4 机并行访存下界 7.20 ms
TP=4 同步墙：每词 366 跳
TCP 24.3 ms，RDMA 14.4 ms
PP=4 层间切分：仅 4 跳/词
单流 28.9 ms (通信 0.08 ms)
PP=4 + MTP 投机微批流水：
4 机满载并发达 96.5 tok/s