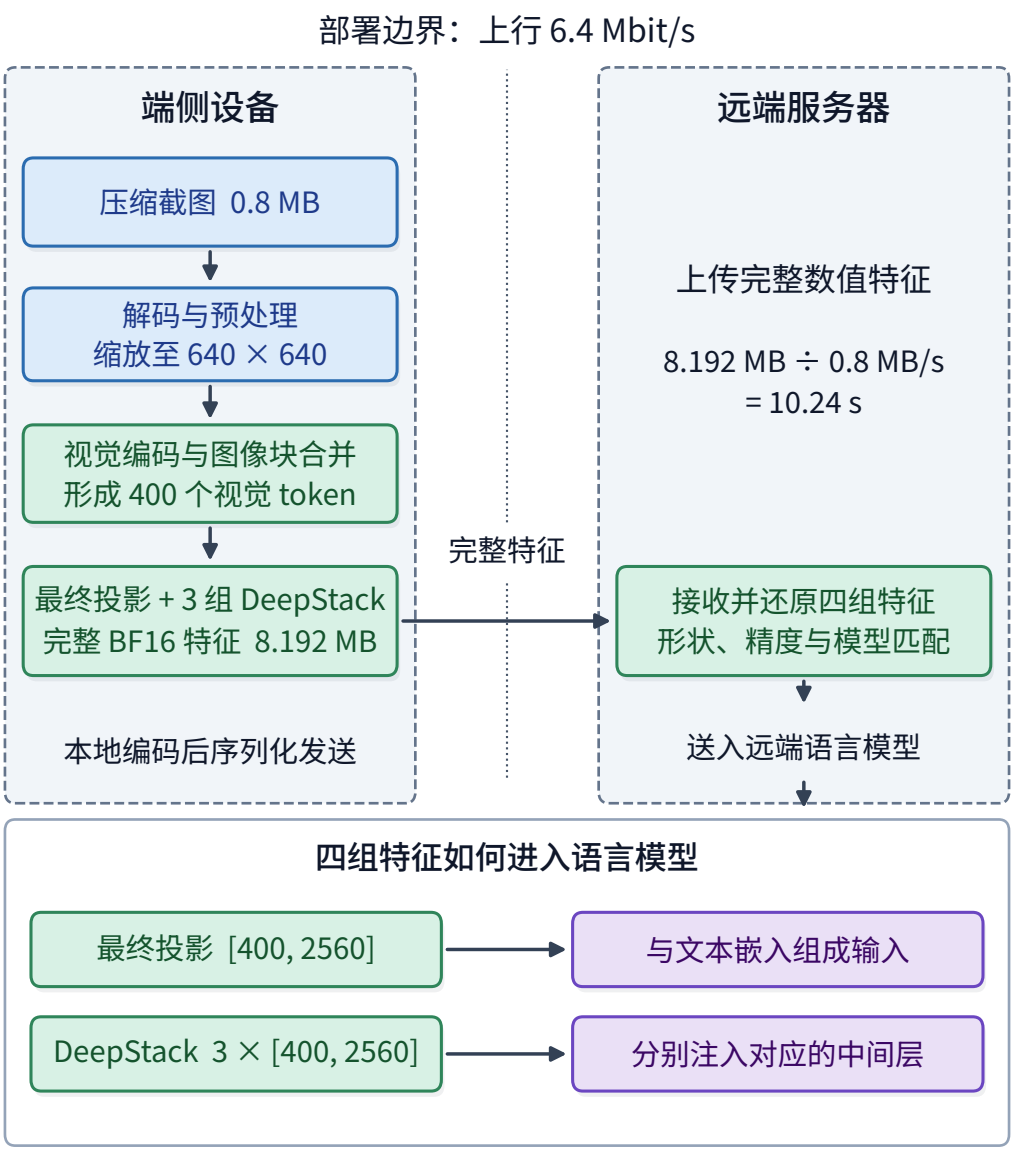
部署边界：上行 6.4 Mbit/s
端侧设备
压缩截图 0.8 MB
解码与预处理
缩放至 640 × 640
视觉编码与图像块合并
形成 400 个视觉 token
最终投影 + 3 组 DeepStack
完整 BF16 特征 8.192 MB
本地编码后序列化发送
完整特征
远端服务器
上传完整数值特征
8.192 MB ÷ 0.8 MB/s
= 10.24 s
接收并还原四组特征
形状、精度与模型匹配
送入远端语言模型
四组特征如何进入语言模型
最终投影 [400, 2560]
与文本嵌入组成输入
DeepStack 3 × [400, 2560]
分别注入对应的中间层