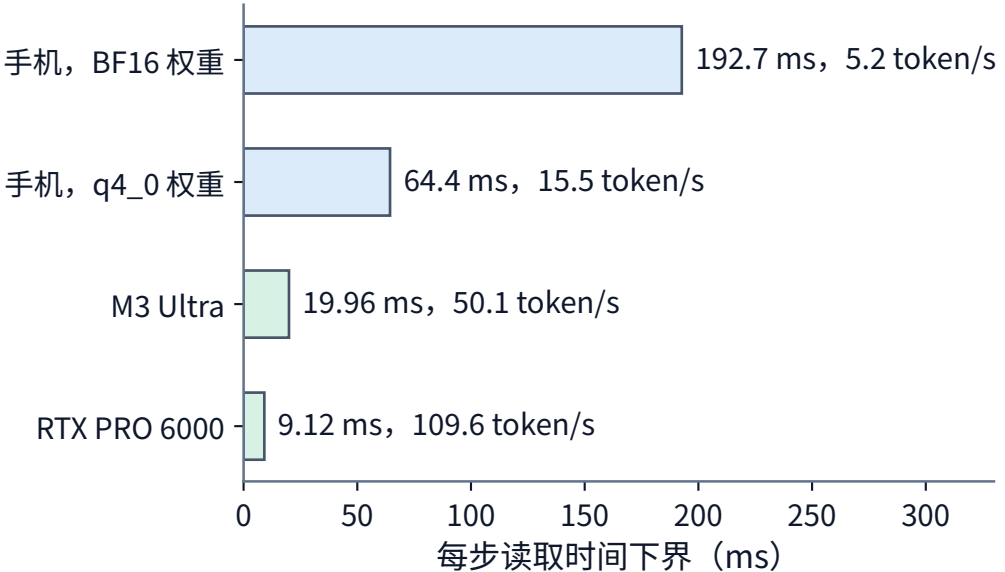
手机，BF16 权重
192.7 ms，5.2 token/s
手机，q4_0 权重
64.4 ms，15.5 token/s
M3 Ultra
19.96 ms，50.1 token/s
RTX PRO 6000
9.12 ms，109.6 token/s
0
50
100
150
200
250
300
每步读取时间下界（ms）