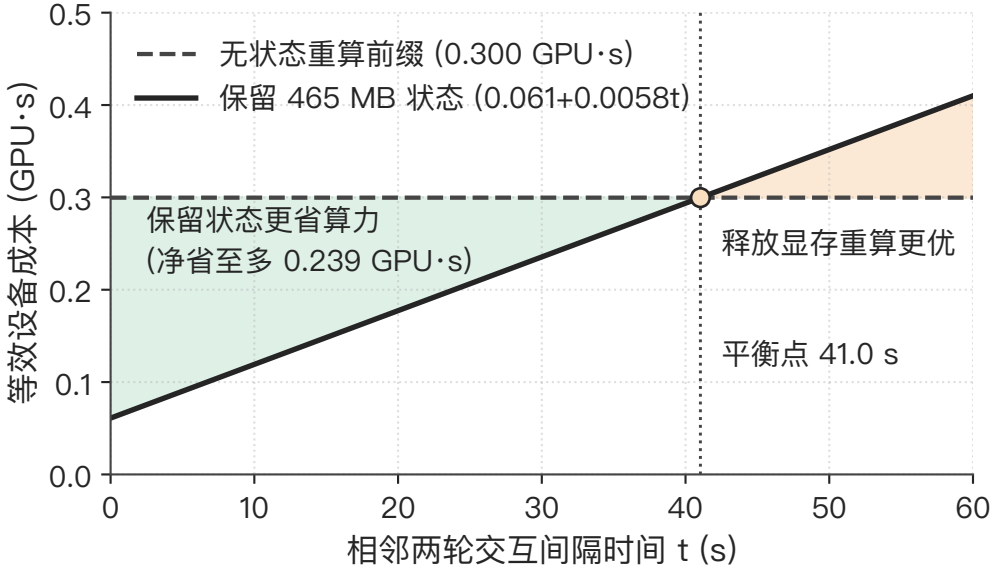
无状态重算前缀 (0.300 GPU·s)
保留 465 MB 状态 (0.061+0.0058t)
保留状态更省算力
(净省至多 0.239 GPU·s)
释放显存重算更优
平衡点 41.0 s
等效设备成本 (GPU·s)
相邻两轮交互间隔时间 t (s)
0.0
0.1
0.2
0.3
0.4
0.5
0
10
20
30
40
50
60