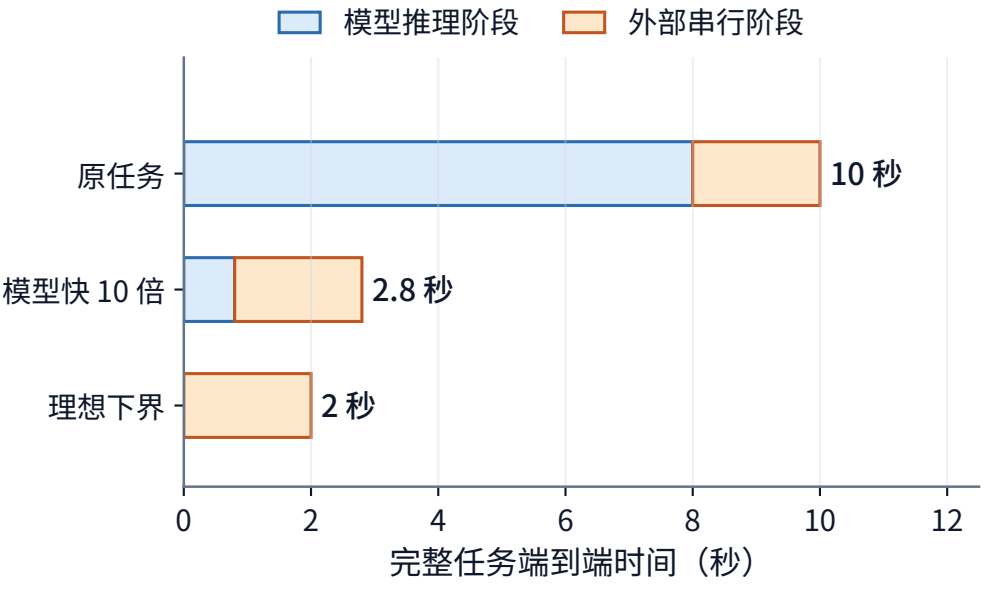
模型推理阶段
外部串行阶段
原任务
模型快 10 倍
理想下界
10 秒
2.8 秒
2 秒
0
2
4
6
8
10
12
完整任务端到端时间（秒）