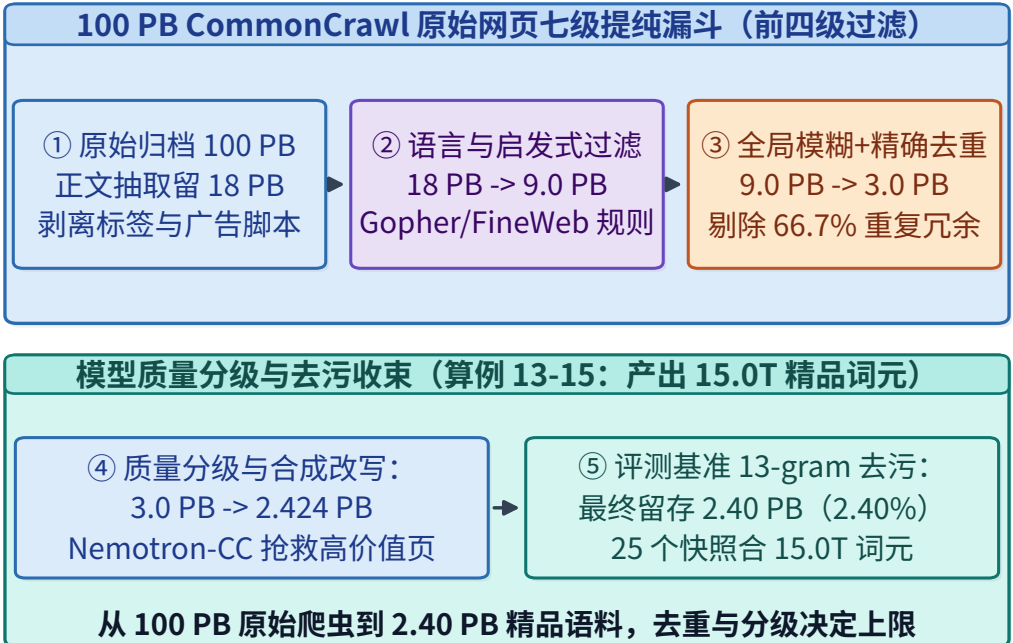
100 PB CommonCrawl 原始网页七级提纯漏斗（前四级过滤）
① 原始归档 100 PB
正文抽取留 18 PB
剥离标签与广告脚本
② 语言与启发式过滤
18 PB -> 9.0 PB
Gopher/FineWeb 规则
③ 全局模糊+精确去重
9.0 PB -> 3.0 PB
剔除 66.7% 重复冗余
模型质量分级与去污收束（算例 13-15：产出 15.0T 精品词元）
④ 质量分级与合成改写：
3.0 PB -> 2.424 PB
Nemotron-CC 抢救高价值页
⑤ 评测基准 13-gram 去污：
最终留存 2.40 PB（2.40%）
25 个快照合 15.0T 词元
从 100 PB 原始爬虫到 2.40 PB 精品语料，去重与分级决定上限