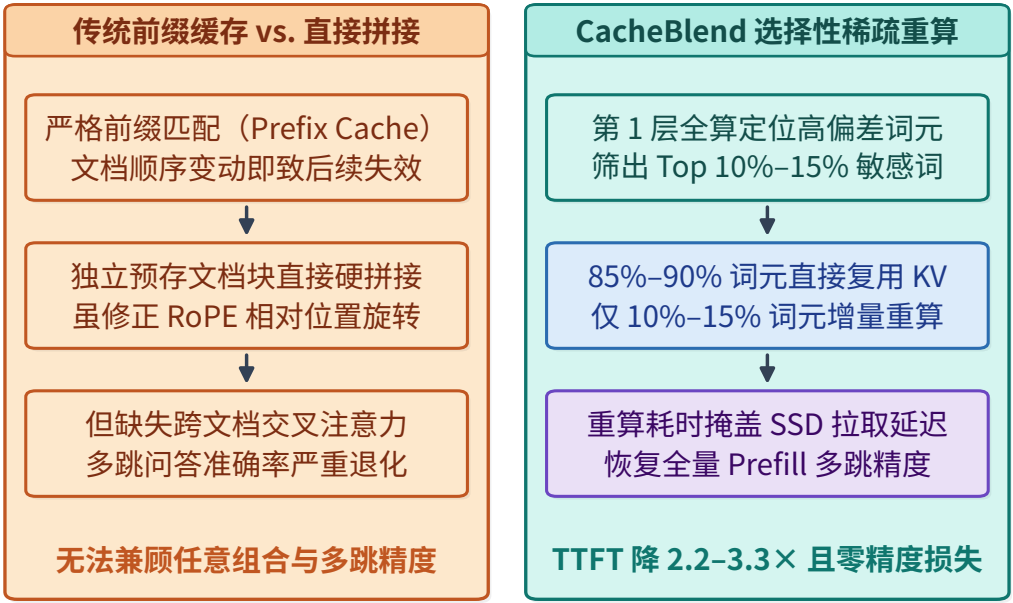
传统前缀缓存 vs. 直接拼接
严格前缀匹配（Prefix Cache）
文档顺序变动即致后续失效
独立预存文档块直接硬拼接
虽修正 RoPE 相对位置旋转
但缺失跨文档交叉注意力
多跳问答准确率严重退化
无法兼顾任意组合与多跳精度
CacheBlend 选择性稀疏重算
第 1 层全算定位高偏差词元
筛出 Top 10%–15% 敏感词
85%–90% 词元直接复用 KV
仅 10%–15% 词元增量重算
重算耗时掩盖 SSD 拉取延迟
恢复全量 Prefill 多跳精度
TTFT 降 2.2–3.3× 且零精度损失