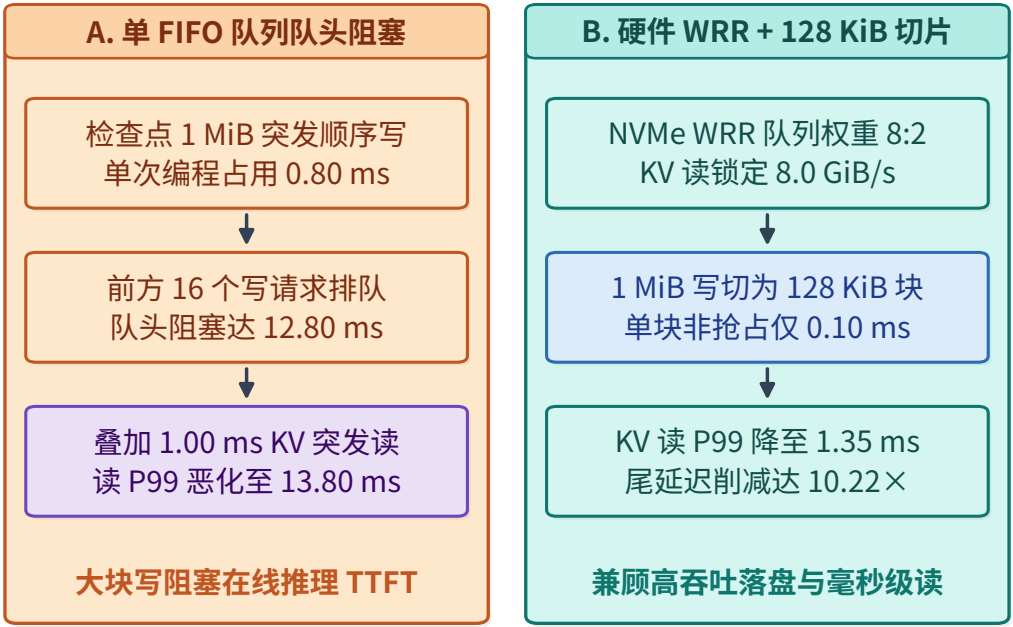
A. 单 FIFO 队列队头阻塞
检查点 1 MiB 突发顺序写
单次编程占用 0.80 ms
前方 16 个写请求排队
队头阻塞达 12.80 ms
叠加 1.00 ms KV 突发读
读 P99 恶化至 13.80 ms
大块写阻塞在线推理 TTFT
B. 硬件 WRR + 128 KiB 切片
NVMe WRR 队列权重 8:2
KV 读锁定 8.0 GiB/s
1 MiB 写切为 128 KiB 块
单块非抢占仅 0.10 ms
KV 读 P99 降至 1.35 ms
尾延迟削减达 10.22×
兼顾高吞吐落盘与毫秒级读