纯 GPU 直通 I/O 的算力争用陷阱

大块裸张量（≥256 KiB）
GDS P2P DMA 跑满 PCIe

↓

细粒度随机读 / 解压反序列化
GPU 轮询队列耗尽寄存器

↓

I/O 控制流侵占 SM 槽位
导致主干 GEMM 算子降速

GPU 擅长矩阵算力而非中断轮询

CoPilotIO：CPU 协处理释放 SM

OSDI 26：GPU 仅写轻量门铃
立即切回执行高密矩阵计算

↓

空闲 CPU 核接管队列轮询
完成小块合并与解压校验

↓

就绪后经锁页缓冲 DMA 入卡
100% 归还 SM 给核心算子

按 I/O 粒度与解压需求动态选路