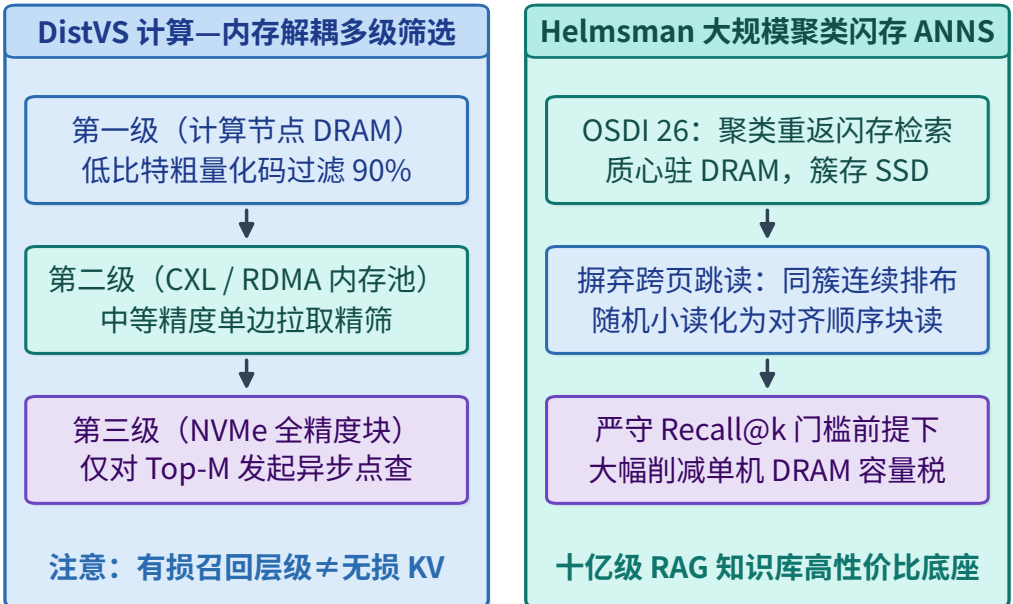
DistVS 计算—内存解耦多级筛选
第一级（计算节点 DRAM）
低比特粗量化码过滤 90%
第二级（CXL / RDMA 内存池）
中等精度单边拉取精筛
第三级（NVMe 全精度块）
仅对 Top-M 发起异步点查
注意：有损召回层级≠无损 KV
Helmsman 大规模聚类闪存 ANNS
OSDI 26：聚类重返闪存检索
质心驻 DRAM，簇存 SSD
摒弃跨页跳读：同簇连续排布
随机小读化为对齐顺序块读
严守 Recall@k 门槛前提下
大幅削减单机 DRAM 容量税
十亿级 RAG 知识库高性价比底座