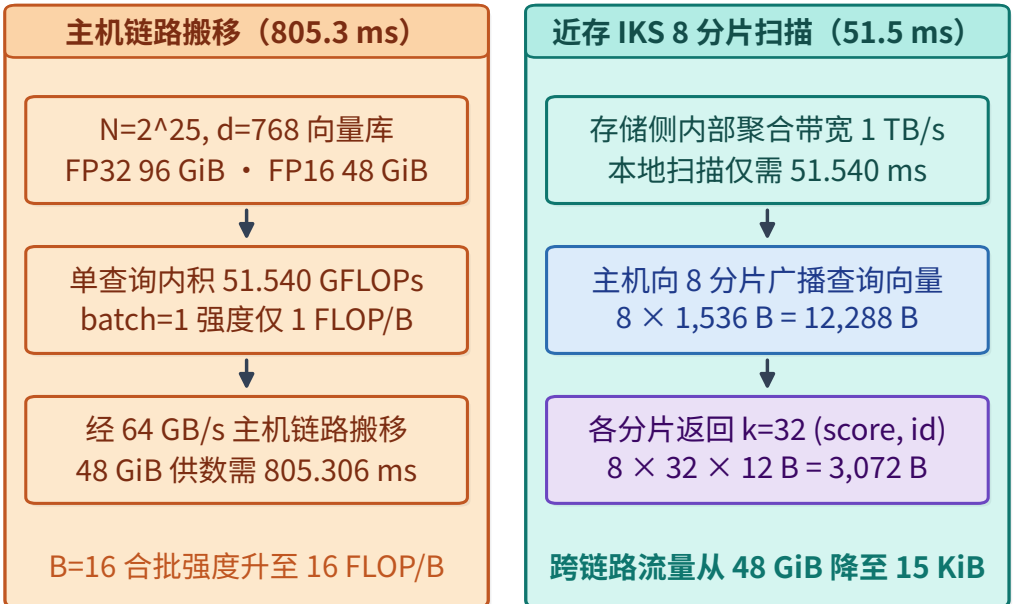
主机链路搬移（805.3 ms）
N=2^25, d=768 向量库
FP32 96 GiB · FP16 48 GiB
单查询内积 51.540 GFLOPs
batch=1 强度仅 1 FLOP/B
经 64 GB/s 主机链路搬移
48 GiB 供数需 805.306 ms
B=16 合批强度升至 16 FLOP/B
近存 IKS 8 分片扫描（51.5 ms）
存储侧内部聚合带宽 1 TB/s
本地扫描仅需 51.540 ms
主机向 8 分片广播查询向量
8 × 1,536 B = 12,288 B
各分片返回 k=32 (score, id)
8 × 32 × 12 B = 3,072 B
跨链路流量从 48 GiB 降至 15 KiB