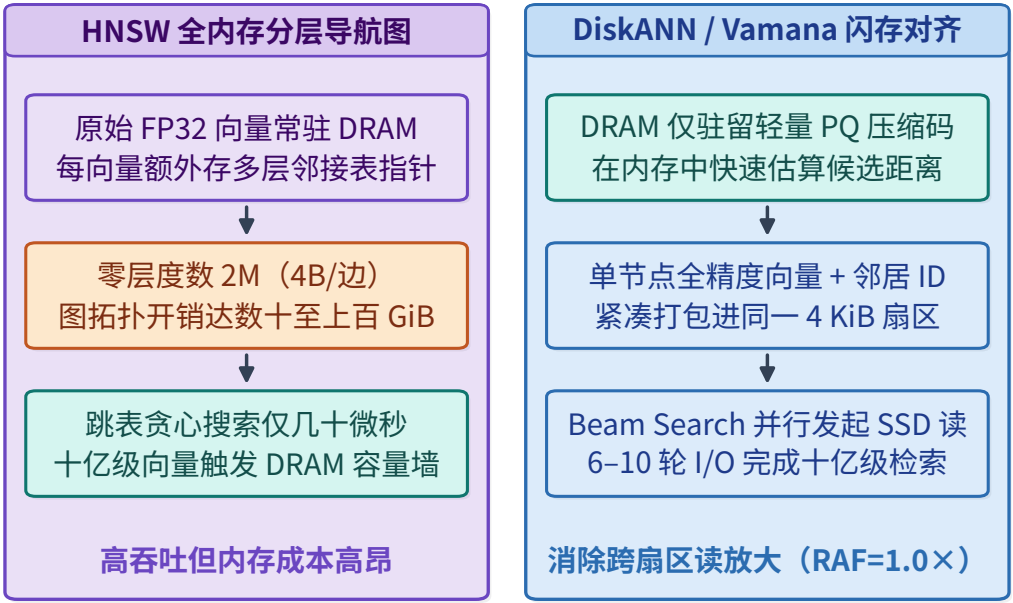
HNSW 全内存分层导航图
原始 FP32 向量常驻 DRAM
每向量额外存多层邻接表指针
零层度数 2M（4B/边）
图拓扑开销达数十至上百 GiB
跳表贪心搜索仅几十微秒
十亿级向量触发 DRAM 容量墙
高吞吐但内存成本高昂
DiskANN / Vamana 闪存对齐
DRAM 仅驻留轻量 PQ 压缩码
在内存中快速估算候选距离
单节点全精度向量 + 邻居 ID
紧凑打包进同一 4 KiB 扇区
Beam Search 并行发起 SSD 读
6–10 轮 I/O 完成十亿级检索
消除跨扇区读放大（RAF=1.0×）