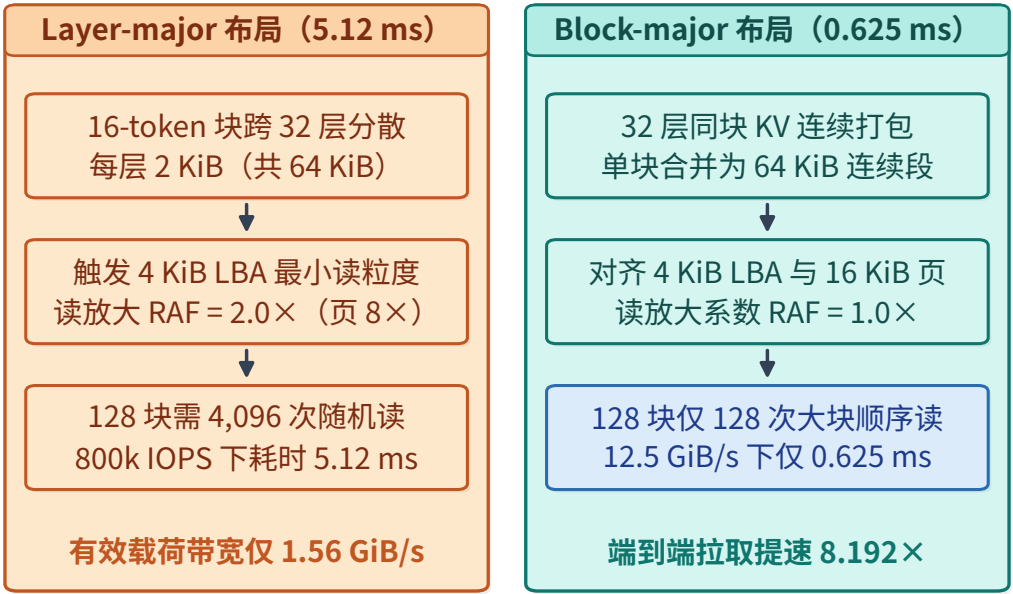
Layer-major 布局（5.12 ms）
16-token 块跨 32 层分散
每层 2 KiB（共 64 KiB）
触发 4 KiB LBA 最小读粒度
读放大 RAF = 2.0×（页 8×）
128 块需 4,096 次随机读
800k IOPS 下耗时 5.12 ms
有效载荷带宽仅 1.56 GiB/s
Block-major 布局（0.625 ms）
32 层同块 KV 连续打包
单块合并为 64 KiB 连续段
对齐 4 KiB LBA 与 16 KiB 页
读放大系数 RAF = 1.0×
128 块仅 128 次大块顺序读
12.5 GiB/s 下仅 0.625 ms
端到端拉取提速 8.192×