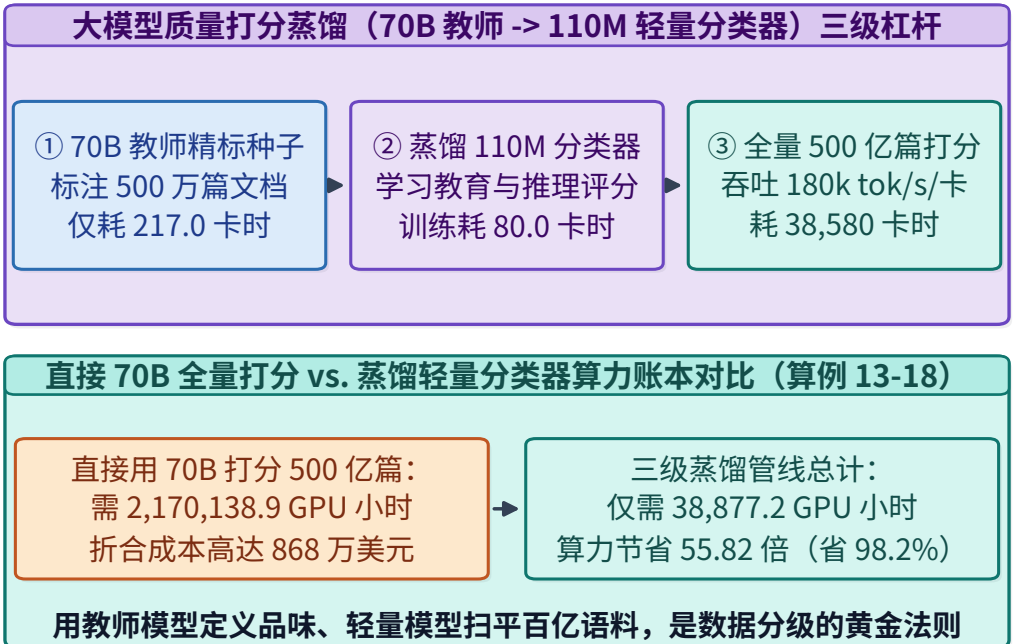
大模型质量打分蒸馏（70B 教师 -> 110M 轻量分类器）三级杠杆
① 70B 教师精标种子
标注 500 万篇文档
仅耗 217.0 卡时
② 蒸馏 110M 分类器
学习教育与推理评分
训练耗 80.0 卡时
③ 全量 500 亿篇打分
吞吐 180k tok/s/卡
耗 38,580 卡时
直接 70B 全量打分 vs. 蒸馏轻量分类器算力账本对比（算例 13-18）
直接用 70B 打分 500 亿篇：
需 2,170,138.9 GPU 小时
折合成本高达 868 万美元
三级蒸馏管线总计：
仅需 38,877.2 GPU 小时
算力节省 55.82 倍（省 98.2%）
用教师模型定义品味、轻量模型扫平百亿语料，是数据分级的黄金法则