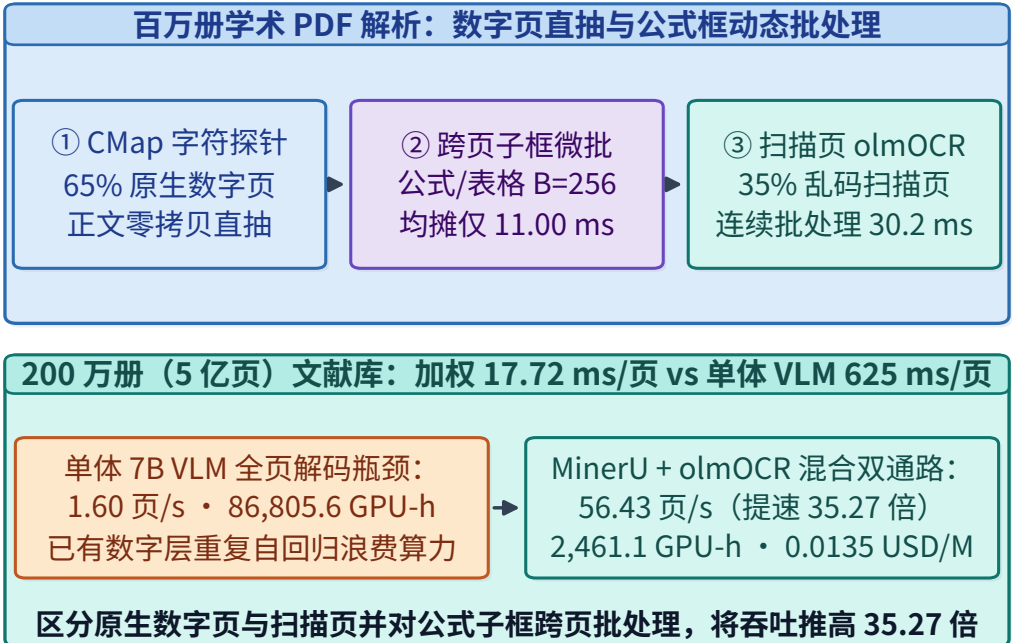
百万册学术 PDF 解析：数字页直抽与公式框动态批处理
① CMap 字符探针
65% 原生数字页
正文零拷贝直抽
② 跨页子框微批
公式/表格 B=256
均摊仅 11.00 ms
③ 扫描页 olmOCR
35% 乱码扫描页
连续批处理 30.2 ms
200 万册（5 亿页）文献库：加权 17.72 ms/页 vs 单体 VLM 625 ms/页
单体 7B VLM 全页解码瓶颈：
1.60 页/s · 86,805.6 GPU-h
已有数字层重复自回归浪费算力
MinerU + olmOCR 混合双通路：
56.43 页/s（提速 35.27 倍）
2,461.1 GPU-h · 0.0135 USD/M
区分原生数字页与扫描页并对公式子框跨页批处理，将吞吐推高 35.27 倍